

附件 2:

第十九届全国大学生信息安全竞赛（作品
赛）暨第三届“长城杯”网数智安全大赛（作
品赛）

作品报告

☐命题赛道

☒自由赛道

作品名称: 面向 AIGC 伪造的跨域泛化检测与可解释性防御平台

电子邮箱: 1830402666@qq.com

提交日期: 2026 年 7 月 5 日

填写说明

1. 所有参赛项目必须为一个基本完整的设计。作品报告书旨在能够清晰准确地阐述（或图示）该参赛队的参赛项目（或方案）。
2. 作品报告采用A4纸撰写。除标题外，所有内容必需为宋体、小四号字、1.5倍行距。
3. 作品报告中各项目说明文字部分仅供参考，作品报告书撰写完毕后，请删除所有说明文字。（本页不删除）
4. 作品报告模板里已经列的内容仅供参考，作者可以在此基础上增加内容或对文档结构进行微调。
5. 为保证网评的公平、公正，作品报告中应避免出现作者所在学校、院系和指导教师等泄露身份的信息。

第十九届全国大学生信息安全竞赛作品赛三等奖 | 仅供学习交流

目录

第一章 作品概述.....	1
1.1 背景分析与威胁模型.....	1
1.2 现有方法的局限性与研究动机.....	2
1.3 作品总体方案.....	5
1.4 项目设计目标.....	6
第二章 作品设计与实现.....	11
2.1 系统总体设计与架构.....	11
2.1.1 五层分层总体架构.....	11
2.1.2 模块划分与完整数据流.....	14
2.2 技术选型与核心算法设计.....	20
2.2.1 Deepfake检测：基于 CLIP ViT-L/14 的高效微调方案.....	21
2.2.2 可解释性检测：MLLM 真实性分析与标准化 JSON 输出.....	26
2.2.3 图片内容安全审核：轻量初筛与多专家级联.....	28
2.2.4 基于多专家协同与混合 RAG 的大模型安全护栏.....	31
2.2.5 Agent执行安全：动作授权与轨迹审查.....	34
2.2.6 来源取证与水印证据链.....	35
2.2.7 统一编排、降级与审计闭环.....	37
2.3 模块接口数据格式.....	37
2.3.1 MLLM 可解释输出标准 JSON格式.....	37
2.3.2 全流程一体化审计报告 JSON结构.....	38
2.4 红线知识库与RAG v2检索子系统.....	39
2.5 软硬件环境部署要点.....	40
第三章 作品测试与分析.....	41
3.1 测试环境与总体方案.....	42
3.2 评测指标与测试方法.....	43
3.3 Deepfake 检测测试与分析.....	44
3.3.1 训练配置与资源.....	44
3.3.2 独立测试集结果.....	45
3.3.3 与基线和不同训练协议的比较.....	45
3.3.4 五折交叉检验.....	47

3.3.5 跨生成器外部测试.....	48
3.3.6 昇腾 910C 工程验收与性能测试.....	49
3.4 图片内容安全测试.....	53
3.4.1 UnsafeBench 统一测试.....	53
3.4.2 NudeNet 专项检测边界.....	53
3.5 Agent 护栏测试（SingGuard NSFA）.....	54
3.6 通用图片真实性测试.....	55
3.6.1 代理数据集测试结果.....	55
3.6.2 无真值盲测边界.....	56
3.7 XGBoost Shadow 旁路测试.....	57
3.7.1 模型定位与配置.....	57
3.7.2 正式站人工标注回放.....	57
3.8 与同类产品对比分析.....	58
3.8.1 图片内容安全对比.....	58
3.8.2 推理性能与部署成本对比.....	60
3.8.3 综合定位与差异化分析.....	61
第四章 创新点与应用价值.....	63
4.1 算法创新：面向跨域的Deepfake检测的参数高效适配与多源联合训练方法.....	63
4.1.1 LN-tuning研究背景与现有微调范式缺陷.....	63
4.1.2 创新技术链路与工程优化.....	64
4.1.3 研发阶段 LN-tuning 对比实验与量化分析.....	67
4.1.4 完整可复现规范.....	68
4.2 取证创新：双层结构化JSON Prompt与可降级证据输出机制.....	68
4.2.1 现有MLLM取证方案缺陷与双层Prompt架构.....	68
4.2.2 创新完整实现技术细节.....	69
4.2.3 结构化 Prompt 机制对比与工程验证.....	70
4.2.4 工程落地创新价值.....	71
4.3 架构创新：真实性与内容安全双主线与五层协同架构.....	71
4.3.1 真实性与内容安全双主线独立建模.....	71

4.3.2 五层架构联动完整创新逻辑	72
4.3.3 多路混合检索与证据融合机制创新	73
4.4 工程创新：面向多专家协同的全链路安全运营平台	74
4.4.1 工程闭环与协同创新	74
4.4.2 异构部署与工程验收	76
4.5 场景应用价值与业务适配	76
第五章 总结	79
5.1 作品完成情况	79
5.2 现存不足后续优化	80
5.3 安全、隐私与伦理约束及未来展望	82
参考文献	83

第十九届全国大学生信息安全竞赛作品赛三等奖 | 仅供学习交流

摘要

随着生成式人工智能（AIGC）技术的快速发展，以扩散模型和Deepfake为代表的生成内容工具大幅降低了伪造内容的制作门槛，由此带来的虚假信息传播、个人隐私侵害与内容安全风险日益严峻。然而，现有检测手段普遍面临四项核心局限：跨数据集泛化能力不足、检测输出缺乏可解释性证据链、图文审核工具功能割裂、算法研究与工程落地严重脱节。

针对AIGC伪造检测、内容安全审核和模型调用风险相互割裂的问题，本文设计并实现了一套面向审核与取证的安全审计平台。系统以CLIP ViT-L/14为视觉主干，采用多数据集参数高效微调和逐脸推理完成Deepfake检测；在独立保留测试集（3,212张）上取得Accuracy 85.59%、Precision 83.28%、Recall 89.04%、F1 86.07%的测试结果。该结果对应本文固定的数据划分与评测协议，不等同于开放世界跨域准确率；在与第三方基线的同协议对比中，Fake Recall提升42.82个百分点。在解释与取证方面，系统通过双层结构化JSON Prompt驱动多模态大模型生成伪造证据、可疑区域锚点和中文分析说明，并结合C2PA、IPTC/EXIF/XMP、SHA-256及平台审计水印形成来源证据链。在内容安全方面，系统构建规则引擎、红线知识库RAG、图片安全多专家和OCR联动的审核链路；在大模型安全护栏方面，融合规则、RAG、Qwen3Guard、SingGuard、MLLM及Agent动作审查，对用户输入、模型输出和工具调用进行分级处置。PerspectiveVision在UnsafeBench测试集（2,037张）上达到Recall 92.15%、F1 84.53%，SingGuard在Agent护栏测试中取得F1 87.98%。在工程层面，平台基于FastAPI与Vue3构建前后端分离架构，支持SSE流式反馈、模块化检测配置、批量并发审计、人工复核和开放API，并完成昇腾910C国产算力环境下的训练验证与异构部署。实验结果表明，平台在本文固定数据集和测试协议下具备跨数据源测试、证据取证、内容安全审核和大模型护栏集成能力；相关指标不外推为开放世界通用准确率或司法鉴定结论。

关键词：AIGC安全审核；Deepfake检测；参数高效微调；大模型安全护栏；红线知识库；来源取证

第一章 作品概述

1.1 背景分析与威胁模型

近年来，扩散模型、多模态大模型技术实现跨越式突破，以Stable Diffusion系列Midjourney及各类开源 Deepfake 人脸换脸模型为代表的 AIGC 生成工具快速普及[1][2]。普通用户仅需简单文字提示即可生成肉眼难以分辨的仿真人像、新闻配图、伪造证件照片；Deepfake 技术可实现人脸人脸替换和音视频合成[3]。开源权重、集成工具和在线服务进一步降低了内容生成与伪造的技术门槛。

AIGC 技术的广泛普及虽然为内容创作提供了极大便利，但也由此牵扯出了不容忽视的内容安全隐患[4][5]，如图1.1 所示。一是虚假信息的蔓延，即利用 AI 生成的图影去捏造虚假新闻或伪造证据，从而对社会信息的健康生态造成威胁；二是个人隐私的损害，如图1.2 所示， Deepfake 技术可能将特定个体的面部图像合成至不雅视频当中，这会严重践踏他人的名誉权与隐私空间；三是潜在的内容安全风险，依托深度伪造技术生成的虚假、低俗、误导性音视频内容，极易滋生各类违规不良信息，扰乱网络内容生态秩序，引发不良舆论导向；四是数字人系统的非法利用，若这类对话系统在安全防护上存在缺失，便极易沦为传播违规内容的媒介。




图1.1 AIGC 发展现状

深度伪造已被广泛应用于身份冒充、网络诈骗和虚假信息传播等场景。短视频平台、直播数字人平台、新闻资讯网站、高校学术管理部门均面临高强度内容审核压力。传统人工审核模式存在效率低、人力成本高、判别标准不统一、难以识别隐蔽

AI 伪造痕迹等缺陷，自动化、高精度、可取证、图文一体化的 AIGC 伪造检测平台成为行业刚需。



图1.2 AI换脸新闻图

1.2 现有方法的局限性与研究动机

当前学术界与产业界已推出多款 Deepfake 图像检测模型与简易文本审核工具，但经过多组横向对比测试，现有方案存在四大无法规避的核心短板，也是本作品核心解决的技术痛点：

短板一：检测模型跨域泛化能力严重不足

早期 Deepfake 检测方法多采用 Xception、EfficientNet 等卷积神经网络作为特征提取骨干^[6]，模型容易过拟合训练数据中特定伪造算法产生的局部纹理、频域噪声等特征。当模型由 FaceForensics++ 等数据集^[6]迁移至 Celeb-DF、DFDC、WildDeepfake等^{[7][8][9]}等包含不同伪造方式的数据集时，检测性能往往出现明显下降，反映出传统方法在跨数据集、跨伪造算法场景下的泛化能力不足。

随着大规模视觉预训练模型的发展，基于Vision Transformer^[10]的CLIP模型凭借大规模图文数据预训练获得了更强的通用视觉表征能力，为提升 Deepfake 检测模型的跨域泛化能力提供了新的技术路径。本系统采用 CLIP ViT-L/14 作为 Deepfake 检测模块的视觉主干网络，利用其预训练视觉编码器提取高层语义与通用视觉特征，而非采用传统 CNN 作为系统主干。如图1.3所示，模型首先对输入人脸图像或视频帧进行预处理，随后通过 CLIP ViT-L/14 视觉编码器提取全局视觉特征，并利用轻量化微调

模块与检测头完成真假二分类。在此基础上，通过轻量化参数微调策略适配 Deepfake 检测任务，尽可能保留 CLIP 预训练阶段形成的通用表征能力，同时降低全参数微调带来的显存占用、训练成本和泛化能力衰减问题。




图1.3 基于 CLIP ViT-L/14 的 Deepfake 检测模型架构

短板二：检测输出黑盒化，缺失完整可取证证据链

许多Deepfake检测器主要输出二元真伪标签与置信度，不直接提供伪造原因、可疑区域和多维异常特征。在司法鉴定、版权维权、学术不端调查等场景中，单一分数难以独立形成可复核的证据材料。部分研究尝试结合多模态大模型提供辅助解释[11]，但工程实现仍可能存在输出格式不稳定、区域定位精度不足和批量归档困难等问题，如图1.4所示。




图1.4 “传统检测瓶颈”示意图

短板三：图像、文本检测工具功能割裂，缺少一体化审核架构

部分 AIGC 安全工具按 Deepfake、文本审核或来源验证等单一能力提供服务，通常需要通过额外编排才能完成图文联合审核；真实业务中的虚假内容可能表现为“伪造图像+违规文字”组合形式。分开使用多套系统会增加审核流程复杂度，因此本文采用统一接入和证据编排方式进行集成。

同时传统文本审核分为两条技术路线：单纯关键词匹配响应速度快^[12]，但无法识别谐音、拆分、变体、隐晦违规表述；纯语义向量检索可识别隐性风险^[13]，工程实现中可借助 Chroma 等向量数据库进行语义向量存储与检索^[14]，但单条文本检索耗时更长，且缺少分级风险判定逻辑，二者单独使用均存在明显缺陷，尚未有工具将两种策略融合落地。

短板四：算法研究与业务工程完全脱节

目前绝大多数 Deepfake 相关论文仅提供模型训练推理代码，无配套前端交互界面、文件解析、批量处理、报告导出、权限管理等工程模块。企业、高校使用时需要从零搭建配套系统，开发周期长、技术门槛高；同时多数开源代码未做异步调度、缓存、并发优化，批量审核场景极易出现服务阻塞、内存溢出问题，无法支撑线上高并发审核需求。

基于上述四类常见工程问题，本作品以“算法适配+完整工程落地”双主线开展设计，构建一套集跨数据源测试、标准化取证解释、图文混合安全审核和可视化运维管理于一体的综合平台。

1.3 作品总体方案

在实际业务治理中，平台明确拒绝将安全风险简单归结为“内容是否由 AI 生成”。真实内容不等于安全。真实拍摄的照片同样可能夹带个人隐私泄漏、违法暴力、自伤或违规营销等业务风险；生成内容不自动等同于危险。合规的 AIGC 艺术创作或数字人交互应被允许合法传播；C2PA 凭证不可单独断言。带有 C2PA 数字凭证的素材仅能证明部分来源可信，无法直接证明其内容安全或完全排除 AI 生成可能性。

因此，本平台打破传统单一点位的检测范式，将真实性鉴别、来源溯源与内容安全进行拆分独立建模。系统将不同链路的模型分歧与凭证冲突视为需要提升优先级的人工复核证据，而非简单用一个单一的“真/假”分数覆盖所有风险。针对传统方案的不足，本作品提出了针对性的应对架构（如表 1.1 所示）。

表 1.1 传统审核方案痛点与本作品应对架构对比

业务痛点	传统方案不足	本作品应对方式
伪造方式快速演化	单一数据集训练的 CNN 易记忆特定伪影，跨域 AUC 明显下降	采用 CLIP 表征与 LN-tuning，尽量保留通用视觉先验
结论难以采信	只输出真/假标签与置信度，缺少可疑区域和文本证据	MLLM 输出固定 JSON，生成证据条目、区域锚点和解释
图文风险割裂	鉴伪工具不审文，文本审核不验证图像来源	真实性链与内容安全链并行，统一在审计报告中呈现
线上审计不可追溯	缺乏权限、证据留存、复核和接口治理	审计链、AES-GCM 证据库、租户 API、人工复核和日志脱敏

为精确描述多维风险判定的逻辑，本平台将综合安全审核问题形式化定义如下：
设系统输入向量为 $I = (x, t, p)$ ，其中 x 表示待审图像， t 表示关联文本或 OCR 提取文本， p 表示文件内置的 C2PA 数字元数据凭证。平台不再简单输出“AI 生成”的单一二分类标签，而是解耦为三大独立判别逻辑：

伪造风险估计： $r_f = f(x)$ ，通过 CLIP-LN-tuning 与 MLLM 计算图像被生成或深度伪造的概率分布及置信度。

内容风险估计： $r_c = g(x, t)$ ，通过敏感词库与 RAG 向量语义检索，评估图文内容在隐私、违法、自伤、未成年人等维度的合规风险等级（safe / review / unsafe）。

来源状态解析： $z = h(p)$ ，通过 C2PA 解析状态机评估凭证链路的完整性（confirmed_source / not_found / inconclusive / invalid_or_tampered）。

系统的最终处置决策 a 由策略融合函数 π 映射生成：

$$a = \pi(r_f, r_c, z, q)$$

其中 q 表示系统健康度向量，涵盖核心模型可用性、证据充分性以及规则冲突状态。当 r_f 与 r_c 均为低风险且 q 正常时，直接予以放行；当命中明确红线规则或极高伪造风险时，自动执行阻断并写库归档；当 r_f 与 r_c 产生分歧，或 z 处于凭证篡改状态时，触发 15 分钟独占租约的人工复核流程；当关键模型服务宕机或证据严重不足时，系统返回不可用兜底状态，严禁静默放行。

1.4 项目设计目标

本项目以“可验证的检测、可信化取证、可组合的多模态审核、工程化落地”为总体建设思路，面向短视频平台、数字人系统、新闻内容审核、高校学术管理及企业内容安全等潜在业务场景，构建兼具算法检测、风险分析、证据留存和业务支撑能力的一体化AIGC内容安全防御平台。

与仅输出“真实/伪造”单一判定结果的传统检测系统不同，本项目不将内容真实性与内容安全性简单等同，而是围绕真实性鉴别、内容风险识别、来源凭证解析和审计处置构建相互独立又协同联动的检测链路。在此基础上，进一步通过结构化证据生成、人工复核、审计留痕和安全存储机制，使检测结果能够由单一模型预测结果转化为可解释、可追溯、可复核的业务决策依据。

本项目确立跨数据源稳健性、面向取证的可解释与可追溯、多模态多维度协同以及工程高可用与隐私合规四项设计目标：

（1）跨数据源稳健性

针对传统 Deepfake 检测模型容易学习特定数据集或特定生成算法伪影、面对未知伪造方式时检测性能明显下降的问题，本项目将提升模型跨数据集、跨生成器和跨业务场景的泛化能力作为首要设计目标。

在视觉检测链路中，采用 CLIP ViT-L/14 作为 Deepfake 检测模块的视觉主干网络^[15]，充分利用大规模图文预训练获得的通用视觉表征能力，降低模型对单一伪造算法局部纹理和特定频域噪声的依赖。在模型适配过程中，通过轻量化参数微调策略^[16]尽可能保留 CLIP 预训练阶段形成的视觉先验，在控制训练参数规模和计算资源消耗的同时，提高模型面对训练阶段未出现的数据分布及新型生成方式时的识别稳定性。

同时，如图1.5所示，系统以多来源数据训练、独立保留测试和跨生成器外部测试评价分布变化下的稳定性。FaceForensics++、Celeb-DF、DFDC和WildDeepfake属于研发阶段参考数据与第三方材料；本报告可复核的正式实验以DF40、OpenRL 、DeepFakeFace 及Inpainting、InsightFace外部子集为准，具体划分和指标见第三章。



图1.5 高跨域泛化性设计示意图

（2）面向取证的可解释与可追溯

针对传统检测模型只输出真伪标签和置信度、检测过程“黑盒化”以及结果难以形成完整证据链的问题，本项目将检测结果的可解释性、证据完整性和全过程可追溯性作为第二项核心目标。

系统在输出 Deepfake 真假概率及风险等级的基础上，引入多模态大模型对检测结果进行辅助分析^[18]，并通过标准化提示词和固定 JSON Schema 约束模型输出格式。如图1.6 所示，系统将伪造判断依据、异常特征、可疑区域锚点、风险等级及置信信息组织为结构化证据，并通过风险区域可视化增强检测结果的可解释性，使审核人员能够进一步理解“风险在哪里、判断依据是什么”。

在证据留存方面，系统围绕“原始文件入库—哈希校验—检测分析—JSON 结构化证据—审计留痕—证据归档”建立全过程证据链，并通过 AES-GCM 加密存储等机制保护证据数据的完整性和机密性。结合审核人员操作日志、人工复核记录和系统处置结果形成完整审计链，为后续版权维权、学术不端调查、企业内部审计及其他合规场景提供可追溯的数据依据。



图1.6 司法级可解释与可追溯设计示意图

（3）多模态多维度协同

针对现有 Deepfake 检测、文本审核和来源验证工具相互割裂的问题，本项目不再将“是否由 AI 生成”作为唯一风险判断依据，而是将真实性鉴别、内容安全和来源状态拆分为相互独立又可协同的检测链路。对于输入图像及其关联文本，系统分别分析图像伪造风险、文本语义风险以及来源凭证状态，避免单一模型结果直接覆盖其他安全维度，系统多模态多维度协同机制如图1.7 所示。

在内容安全层面，系统面向个人隐私、违法活动、违规营销、自伤、未成年人等风险类别开展独立识别，并结合敏感词规则与检索增强生成（RAG）^{[17][18]}语义检

索增强对隐晦、变体和上下文相关违规表达的发现能力。各检测链路的结果最终通过统一策略进行融合，当真实性判断、内容风险或来源凭证之间出现冲突时，不进行简单覆盖，而是提高审核优先级并进入人工复核流程，从而形成更加完整的图文一体化安全审核机制。



图1.7 多模态多维度协同审核机制

（4）工程高可用与隐私合规

针对多数 Deepfake 研究成果停留在模型训练与离线推理阶段、缺少完整业务支撑能力的问题，本项目以可部署、可维护、可扩展为工程建设目标，将核心检测算法封装为完整审核服务。平台面向审核人员提供任务提交、结果查看、人工复核、证据查询和数据驾驶舱等功能，同时通过租户 API 为外部业务系统提供标准化调用接口，并采用 Docker 进行环境封装与部署，降低模型与平台在不同运行环境中的迁移和维护成本，整体工程部署与安全合规架构如图1.8所示。

在高可用与安全方面，系统针对批量审核和多用户访问场景设计任务调度、异常处理及服务状态管理机制，当关键模型服务异常或证据不足时进入明确的兜底状态，避免因局部服务故障产生静默放行。同时坚持最小权限和隐私保护原则，对用户权限、接口访问及敏感日志进行约束，对关键证据进行加密存储并对日志中的敏感字段实施脱敏处理，在保证审核效率和系统可用性的同时，降低原始素材、检测记录及用户信息泄露风险。



图1.8 工程高可用与安全合规架构

第二章 作品设计与实现

2.1 系统总体设计与架构

2.1.1 五层分层总体架构



图2.1 五层分层总体架构

本系统遵循高内聚、低耦合的软件设计思想，结合真实性鉴别、内容安全审核、来源取证、专家模型融合及人工运营等业务需求，如图2.1所示，将系统总体架构划分为接入层、检测层、专家层、决策层和运营层五个层级。五层之间通过标准化接口进行数据传递，各检测能力与专家能力相互解耦，在保证统一编排和证据融合的同时，支持模块独立迭代、按需部署以及故障隔离。

接入层：接入层作为系统统一业务入口，负责外部请求接入、身份验证、权限控制和文件安全检查。系统通过 HTTPS 提供统一服务接口，支持审核员登录、租户 API Key、Scope 权限控制、接口限流和调用配额管理。对于文件类输入，接入层在正式进入检测流程之前统一执行文件类型、文件大小、图像像素以及 SHA-256 等基础校验，防止异常文件、越权调用和非法请求进入核心检测服务。系统同时支持前端交互式调用和开放 API 调用，为后续检测、企业级系统集成及批量审核提供统一入口。

检测层：检测层负责对输入内容执行基础检测和证据提取，是系统产生原始检测证据的核心层。当前检测能力主要包括 Deepfake 检测、通用图片真实性分析、图片

内容安全检测、OCR 文本识别、C2PA 来源验证、文本护栏以及 Agent 安全检测等。对于图像输入，系统首先完成人脸区域定位和质量检查，对满足检测条件的人脸执行五点对齐，并进行逐脸 Deepfake 检测；同时通过通用图片真实性模型分析 AI 生成或图像异常证据。图片内容安全链路采用多模型级联方式完成风险识别。OCR 模块基于 PaddleOCR^[19]负责提取图像中的文字信息，并将识别结果同步送入规则、RAG 和文本安全专家进行分析。对于文本和 Agent 输入，检测层分别执行提示词、模型输出、上下文内容及工具动作、参数、目标、结果和轨迹的安全检查，从而形成覆盖图像、文本和智能体行为的多模态基础检测能力。

专家层：专家层负责对检测层产生的原始数据进行专业化分析和交叉验证。该层由规则系统、RAG 知识检索、Qwen3Guard、SingGuard、PerspectiveVision、MLLM 以及本地 XGBoost Shadow 等专家组件组成。不同专家针对不同类型风险提供独立证据。例如，规则和 RAG 主要用于政策、标准、业务红线以及敏感知识的精准匹配；Qwen3Guard、SingGuard 等安全专家用于文本安全判断；PerspectiveVision 等视觉专家用于图像风险复核；MLLM 负责复杂多模态场景中的综合解释和证据归纳。各专家之间不采用简单的单模型替代关系，而是分别输出独立分析结论和置信信息，为决策层提供多源证据。

决策层：决策层负责融合真实性证据、内容风险证据、来源证据以及系统健康状态，形成最终业务处置结果。系统摒弃“单模型分数决定最终结果”的简单判定方式，根据多类证据一致性、风险等级、模型分歧情况及关键服务运行状态，统一输出 safe、review 或 unsafe 等业务状态；当关键检测服务不可用、核心证据不足或无法形成可信结论时，系统返回 unavailable 或 inconclusive，不得将服务失败静默视为安全结果。其中，低风险且多项证据相互一致时可自动放行；命中明确安全红线或高风险证据充分时进入阻断流程；存在模型分歧、低质量人脸、来源异常或证据不足时进入人工复核。

运营层：运营层负责人工复核、日志取证、统计评测、开放 API 管理、数据总览以及驾驶舱可视化等运营工作。系统对检测过程中的关键输入、模型输出、证据状态和最终处置结果进行全过程审计。对于自动化模型无法可靠判断的任务，运营层将任务送入人工复核流程，由审核人员结合真实性证据、内容安全证据和来源信息进行最终确认。

同时，运营层通过统计分析、模型评测、业务指标汇总和驾驶舱大屏，为系统运维、风险治理和模型迭代提供数据支撑。

表 2.1 五层架构核心组件、输入输出

层级	核心组件	输入与输出
接入层	HTTPS、审核员登录、API Key、Scope、限流、配额、文件安全校验	接收图片、文本、Agent 及 API 请求；完成权限验证和文件安全检查
检测层	Deepfake、图片真实性、图片内容安全、OCR、C2PA、文本护栏、Agent 安全规则、RAG、Qwen3Guard、	输出真实性、内容风险、OCR 文本、来源验证及行为安全等原始证据
专家层	SingGuard、PerspectiveVision、MLLM、XGBoost Shadow	对检测结果进行专业复核和多模型交叉分析，输出专家证据及解释
决策层	多证据融合、风险分级、降级策略	综合证据输出 safe、review、unsafe 或 unavailable/inconclusive
运营层	人工复核、日志取证、统计评测、开放 API、数据总览、驾驶舱	输出最终处置结果、审计记录、统计指标及可复现证据

五层架构采用解耦设计思路，核心组件、输入输出如表2.1所示。不同检测模块和专家模块均可按业务需求独立启停。例如，在仅执行文本安全审核时，可不加载 Deepfake 和视觉真实性模型；在仅执行图片鉴伪时，也可以关闭文本审核相关专家。各模块通过标准化 JSON 数据结构传递证据，新增音频、视频或其他检测能力时，可优先在检测层增加新的检测子模块，并在专家层扩展对应专家，而无需整体重构系统。需要特别指出的是，系统中的不同证据回答的是不同问题，不能进行简单混判。Deepfake 检测用于判断人脸区域是否存在换脸或局部操纵痕迹；通用图片真实性用于分析 AI 生图或整体异常；内容安全用于判断输入是否存在违规或业务风险；C2PA 及元数据用于验证来源和资产链信息。因此，C2PA 验证成功不等于图片一定由 AI 生成，未检测到 C2PA 凭证也不代表图片一定真实；AI 生成概率同样不能代替内容安全结论。

2.1.2 模块划分与完整数据流

1. 核心模块划分




图2.2 双主线核心模块与统一处置架构图

系统根据当前正式能力划分为多个相互解耦的核心业务模块，如图2.2 所示：

Deepfake 逐脸检测模块：Deepfake 模块主要针对人脸换脸、局部操纵及相关伪造场景。输入图片经过人脸区域检测和质量检查后，对有效人脸进行五点对齐，并采用当前生产环境中的多数据集 PEFT 模型执行逐脸检测。系统不再简单对整张图片输出单一真伪结果，而是针对每一个有效人脸分别产生检测证据，从而适应多人图像以及局部伪造场景。

通用图片真实性模块：该模块用于补充 Deepfake 对非人脸 AI 生图和整体图像生成痕迹覆盖不足的问题。生产环境通过多模态模型判断图像为 real、fake或uncertain，并将其作为AI生图和通用真实性分析的辅助证据。该模块结论不会直接替代 Deepfake 或来源验证结果，而是作为独立真实性证据进入后续决策。

图片内容安全模块：图片内容安全采用级联审核机制。系统首先通过 MultiHeaded+Q16完成快速初筛，对高风险或存在疑问的样本调用 PerspectiveVision 进行进一步复核，并结合 NudeNet 完成人体成人区域专项检测，最终由 MLLM 对复杂风险场景进行解释。通过多阶段级联机制，可以降低单模型误判对最终结果的影响，并将存在风险或模型分歧的内容送入人工复核。

文本护栏模块：文本安全审核不再仅依赖关键词和单一RAG 检索，而是采用规则、RAG、Qwen3Guard、SingGuard 和 MLLM 等多种专家并行分析。规则和敏感词用于快速识别明确红线；RAG 用于召回法规、标准、平台规则和内部知识；安全模型用于分析复杂语义风险；MLLM 则承担补充解释和综合分析工作。系统可以同时保护用户输入提示词和模型输出文本，实现输入、输出双向内容安全保护。

Agent安全模块：Agent 安全模块针对大模型智能体执行工具调用过程中产生的安全风险进行检查。系统重点分析工具名称、调用参数摘要、目标、执行结果及完整轨迹。在高风险动作执行前，系统可触发动作前检查或一次性审批；执行结束后再次复检工具结果和调用轨迹，用于防止工具滥用、间接提示词注入及高风险自动化操作。

来源取证模块：来源取证模块通过 C2PA、IPTC、EXIF、XMP、ICC、SHA-256 和内部审计水印等信息分析媒体文件的来源与完整性。其中，C2PA 采用多状态结果进行表达，不将“未找到凭证”简单判定为“真实”，也不以 C2PA 单独证明 AI 生成状态。

红线知识与 RAG 模块：红线知识库统一管理法规、行业标准、平台规则、内部制度及关键词数据，并通过关键词匹配和向量语义检索完成混合召回。检测过程中，系统能够输出具体命中的知识标题、来源、相关条款、相关度及建议，为风险判定提供可解释依据。

系统后端服务基于 FastAPI^[20]框架实现异步调度与多链路并行编排；前端展示层基于 Vue3^[21]+TypeScript+Element Plus^[22]构建 SPA 应用（如图2.3 所示），提供拖拽上传、模块化检测链路选择、可疑区域辅助预览、阶段结果展示与审计记录查看等功能。每个模块均独立封装异常捕获逻辑，单点专家服务异常不会导致整个审核流程中断。




图2.3 前端可视化界面

2. 多证据判定与处置规则

平台摒弃传统的“单一分数决定一切”的简单逻辑，将真实性证据、内容安全证据、来源证据以及系统健康状态进行独立分析并在决策层统一融合，如表2.2所示。不同类型证据分别回答不同问题，避免将 Deepfake 检测结果、通用 AI 生图概率、内容安全状态以及 C2PA 来源凭证混为同一类结论。

该设计能够避免“鉴伪未命中即直接放行”或“存在可信来源即认为内容安全”等逻辑漏洞。例如，真实拍摄的图片仍可能包含违法违规或其他高风险内容；AI 生成图片也不一定自动构成内容安全风险；同样，C2PA 来源凭证仅能够说明媒体资产的来源链状态，不能单独作为图片是否真实或是否由 AI 生成的判定依据。

表2.2 多证据判定机制与人工复核处置规则

证据链路	回答的问题	典型输出	边界
真实性证据	是否存在换脸、局部操纵、AI 生图或其他真实性异常？	逐脸 Deepfake 结果、通用图片真实性 real/fake/uncertain、MLLM 辅助证据	不以单一模型分数直接断言整体真实或伪造
内容安全证据	是否包含违法违规、个人数据、自伤、营销违规等业务风险？	safe/review/unsafe、多标签风险、规则、RAG 及专家证据	真实内容不等于安全；生成内容也不自动等于危险
来源证据	是否存在可验证的来源凭证、元数据或篡改迹象？	C2PA 四态、IPTC / EXIF / XMP / ICC、SHA-256、内部审计水印	C2PA 验证成功不代表一定由 AI 生成；未找到凭证也不代表内容真实
系统健康状态	核心检测服务或专家服务是否正常可用？	healthy / degraded / unavailable 等状态	关键服务故障不得静默按照 safe 处理
人工复核	自动模型分歧、低质量输入、来源异常或证据不足时如何处置？	review、证据查看、人工判定及审计记录	自动化结果不能代替证据不足场景下的人工最终复核

最终动作由决策层综合真实性证据、内容安全证据、来源证据和系统健康状态生成，可表示为：

$$a = \Pi(E_{auth}, E_{safety}, E_{prov}, H) \in \{safe, review, unsafe, unavailable\}$$

其中， E_{auth} 表示真实性证据， E_{safety} 表示内容安全证据， E_{prov} 表示来源证据， H 表示系统健康状态。

当内容风险较低、主要证据相互一致且核心服务运行正常时，系统输出 **safe**；当命中明确红线或高风险证据充分时，输出 **unsafe** 并写入审计记录；当模型之间存在明显分歧、低质量人脸、来源异常或证据不足时，输出 **review** 并进入人工复核；当关键服务故障或核心证据无法正常获取时，返回 **unavailable** 或 **inconclusive**，不得将服务异常静默判定为 **safe**。

3. C2PA 来源验证状态机

来源验证采用 C2PA 标准的四态输出状态机进行硬性约束：

confirmed_source：来源链验证完全通过，具备可信数字签名与完整的资产绑定记录。

not_found: 未在媒体文件中发现兼容的 C2PA 凭证或来源声明。该状态仅表示未检测到相关凭证，不能据此认定媒体内容真实。

inconclusive: 由于解析器不可用、数字证书状态异常、证据链信息不足或其他技术原因，当前无法形成明确的来源验证结论。

invalid_or_tampered: 数字签名验证失败、资产哈希绑定无效，或者来源证据链存在明确异常或篡改迹象。

4.完整业务数据流

系统的完整业务处理流程采用前置校验、并行检测、专家分析、证据融合与人工复核相结合的调度策略，如图2.4 所示。系统针对不同类型输入分别生成真实性证据、内容安全证据和来源证据，并结合系统健康状态完成最终处置，具体流程如下。

第一步：请求接入与文件安全校验

用户通过前端页面或开放 API 提交图片、文本或相关审核任务。FastAPI^[20]网关接收请求后，对用户身份、API Key、Scope 权限及调用配额进行检查；对于图片文件，同时执行文件类型、文件大小、图像像素以及 SHA-256 校验。校验通过后，系统为任务分配唯一 UUID，并进入后续检测流程；

第二步：人脸区域检测与质量前置

对于图片输入，系统首先通过 Haar 人脸检测获取候选人脸区域并生成质量卡，对人脸大小、清晰度及有效性进行前置检查。对于无法满足 Deepfake 检测条件的人脸，不强制输出真伪结论，而是记录低质量或不可判定状态，供后续决策层参考；

第三步：逐脸 Deepfake 检测与通用真实性分析

有效人脸区域经 YuNet 完成五点关键点对齐后，逐脸送入平台 Deepfake 模型执行推理，分别输出各人脸的真实性检测结果及相关证据。当前生产 Deepfake 模型以第三方 CLIP ViT-L/14 checkpoint 为初始化基础，由本项目完成多数据集参数高效微调、SLERP 增强以及逐脸推理等工程化实现。与此同时，原始图片进入通用图片真实性分析链路，由生产 MLLM 对整图执行 real / fake / uncertain 辅助判断，用于覆盖全生成肖像、证件图及非人脸图片等逐脸 Deepfake 模型难以覆盖的场景。该结果作为独立真实性证据，不与 Deepfake 结果进行简单替代；

第四步：图片内容安全级联审核

图片内容安全链路与真实性检测并行运行。系统首先通过 MultiHeaded+Q16 执行低延迟初筛，对潜在高风险或存在不确定性的内容进一步调用 PerspectiveVision-

LLaVA 进行高召回二审；同时结合 NudeNet 对成人相关区域进行专项识别，并由 MLLM 对复杂风险内容生成中文解释证据。各级模型分别保留自身检测结果和风险标签，避免由单一视觉模型直接决定最终内容安全状态；

第五步：OCR 与文本护栏分析

系统对图片中的文字信息执行 OCR 提取，并将 OCR 文本与用户直接提交的文本共同送入文本护栏。文本护栏首先执行始终启用的规则和红线知识匹配，并结合 RAG 检索召回相关法规、标准、平台规则和内部红线条目；随后调用 Qwen3Guard 对文本输入或模型输出进行安全分类，并根据任务类型调用 SingGuard 对 Agent/NSFA 相关风险进行补充判断，MLLM 则负责复杂场景的解释和证据归纳。不同专家结果分别输出，不以某一个专家模型结果覆盖其他证据；

第六步：来源取证与完整性分析

来源取证链路并行执行 C2PA 验证，并进一步提取 IPTC、EXIF、XMP、ICC 等媒体元数据，同时结合 SHA-256 和内部审计水印形成来源证据。C2PA 验证结果采用 confirmed_source、not_found、inconclusive 和 invalid_or_tampered 四态表达。来源证据仅回答媒体来源及凭证状态问题，不直接替代 Deepfake、通用图片真实性或内容安全结论；

第七步：Agent 安全检查

对于涉及 Agent 或工具调用的任务，系统进一步检查工具名称、参数摘要、执行目标、调用结果及完整轨迹。在动作执行前可根据风险触发安全检查或一次性审批，执行结束后继续进行结果复检和轨迹审查。SingGuard 主要用于 Agent/NSFA 场景分析，本地 XGBoost Shadow 仅进行旁路预测和模型分歧挖掘，其结果不改变生产主链的最终结论^[23]。当外部专家型不可用时，系统显式记录 degraded 或 unavailable 状态；

第八步：阶段结果返回与状态更新

各检测链路每完成一个处理阶段，即将阶段状态、风险结果和相关证据封装为标准 JSON 数据，并通过系统实时通信机制返回前端。前端可分别查看真实性、内容安全、来源取证及专家状态，避免将不同证据维度混合展示；

第九步：多证据融合与最终处置

全部核心检测流程结束后，决策层统一接收真实性证据、内容安全证据、来源证据以及系统健康状态，并按照多证据判定策略生成最终处置结果。当内容风险较低、

主要证据相互一致且核心服务运行正常时，系统输出 **safe**；当命中明确红线或高风险证据充分时输出 **unsafe**；当存在模型分歧、低质量人脸、来源异常或证据不足时输出 **review**，并进入人工复核；当关键服务故障或核心证据无法获取时返回 **unavailable** 或 **inconclusive**，不得将服务异常静默判定为 **safe**；

第十步：审计、人工复核与结果存储

系统将任务输入摘要、各检测模块结果、专家证据、来源状态、最终决策及关键处置过程写入审计记录。需要人工判断的任务进入人工复核流程，复核结果继续纳入审计链。最终系统保存标准化 JSON 审计数据，并向前端提供检测结果展示、历史任务查询、人工复核以及统计分析等功能。




图2.4 业务技术流程图

2.2 技术选型与核心算法设计

本节的核心不是将多个模型简单串联，而是建立“证据优先、专家解耦、保守融合、失败显式化、人工闭环”的审核框架。系统将真实性证据、内容安全证据、来源证据和系统健康状态分别建模，各专家只回答其职责范围内的问题，并通过标准化 JSON 返回状态、分数、证据、耗时和错误码。策略层在保留证据来源的前提下生

成业务处置，避免将 Deepfake 概率、AI 生图判断、内容违规和 C2PA 来源凭证压缩为一个不可解释的总分。

$$(E = (E_{auth}, E_{safe}, E_{prov}, E_{health}))$$

最终处置由策略函数 $D = \Pi(E, P)$ 生成，其中 P 表示当前 profile、阈值和业务规则， $D \in \{safe, review, unsafe, inconclusive, unavailable\}$ 。前三级描述内容处置，后两级描述证据或服务状态；任何关键专家失败都不得静默解释为 safe。

2.2.1 Deepfake检测：基于 CLIP ViT-L/14 的高效微调方案

面对不断演进的人脸伪造与生成技术，传统 Deepfake 检测方法往往依赖混合边界不一致、头部姿态异常、眼部闪烁或局部纹理异常等特定伪造痕迹。随着生成模型与换脸技术持续迭代，这类人工归纳偏置在未知生成器和跨数据集场景下容易出现明显性能衰减。为提高模型对不同伪造来源的泛化能力，本系统采用 CLIP ViT-L/14 作为 Deepfake 检测模型的视觉表征骨干，并以第三方预训练 checkpoint 为初始化基础，由本项目完成面向平台业务数据的多数据集参数高效微调、特征增强及生产推理集成。本系统 Deepfake 检测从人脸预处理、模型推理到结果输出的整体技术链路如图 2.5 所示。




图2.5 Deepfake检测技术链路

在生产推理流程中，系统首先对输入图像执行人脸区域检测与质量前置。通过 Haar 人脸检测获取候选人脸区域，并对人脸尺寸、清晰度及有效性进行质量评估；对于满足检测条件的人脸，进一步采用 YuNet 获取五点关键点并完成人脸对齐^[24]。

经过对齐的人脸区域分别送入 Deepfake 模型执行逐脸推理，从而获得各人脸独立的真实性检测结果。

与直接针对整幅图像输出单一真伪标签相比，逐脸检测能够更好地处理多人图像和局部换脸场景。模型前向推理结构及多数据集参数高效微调、SLERP 特征增强等训练优化策略如图 2.6 所示。



图2.6 ViT-L/14前向推理与训练优化策略示意图

当图片中仅有部分人脸被篡改时，系统仍保留每张人脸的独立检测证据，并以各人脸伪造概率的最大值作为图片级风险分数。当前生产阈值不是简单二分： $s_{df} \geq 0.80$ 输出 fake；当 $s_{df} \leq 0.20$ 且所有人脸均完成关键点对齐时输出 real；其余边界样本输出 review。未检出有效人脸、模型加载失败或预处理不可用时输出 inconclusive/degraded，不强制归为 real。界面 $confidence = \max(s_{df}, 1 - s_{df})$ ，但该 Softmax 值尚未经过生产分布校准，不能解释为统计置信区间。

在模型结构方面，本方案采用预训练的 CLIP ViT-L/14 图像编码器作为视觉特征提取骨干。CLIP 在大规模图文数据上学习得到的通用视觉语义先验，为模型识别人脸纹理、边缘结构以及潜在生成特征提供了良好的初始化基础。考虑到直接进行全参数训练会显著增加计算开销，并可能破坏预训练模型已有的通用视觉表征能力，本项目采用参数高效微调策略，在保留预训练先验的同时，使模型进一步适应 Deepfake 人脸真实性判别任务。

具体而言，设冻结的 CLIP 视觉主干为 θ_f ，可训练参数集合为 $\theta_{\text{train}} = \theta_{\text{LN}} \cup \theta_{\text{head}}$ 。对齐后的人脸图像 x_i 经视觉编码器得到 $h_i = f_{\theta_f}(x_i)$ ，二分类头计算 $z_i = W h_i + b$ 。

$$(p_i(k) = \frac{\exp(z_{i,k})}{\sum_{j \in \{\text{real}, \text{fake}\}} \exp(z_{i,j})}, \quad p_i^{\text{fake}} = p_i(\text{fake}))$$

$$(s_{\text{df}} = \max_{1 \leq i \leq n} p_i^{\text{fake}})$$

训练采用带标签平滑的交叉熵 $\mathcal{L}_{\text{CE}} = -\frac{1}{N} \sum_{i=1}^N \sum_{c \in \{\text{real}, \text{fake}\}} \tilde{y}_{i,c} \log p_i(c)$ ，其中 $\tilde{y}_{i,c} = (1 - \varepsilon) y_{i,c} + \frac{\varepsilon}{2}$ 。训练时冻结 CLIP 主干，仅更新 LayerNorm 与二分类头，即 $\nabla_{\theta_f \setminus \theta_{\text{LN}}} \mathcal{L}_{\text{CE}} = 0$ ；这一 LN-tuning 方案以少量参数适应任务分布，降低全参数微调的计算量和灾难性遗忘风险。

需要说明的是，本项目并非从零训练 CLIP ViT-L/14 的全部参数，而是在第三方 checkpoint 基础上完成平台侧的多数据集参数高效微调、训练策略优化以及系统工程集成。因此，模型的准确技术定位应表述为“基于第三方预训练模型初始化完成平台多数据集微调与生产适配”，非完全自主从零训练全部模型权重。

为进一步增强模型对未知分布（Out-of-Distribution, OOD）伪造样本的鲁棒性，本方案研发阶段研究了特征空间正则化，并在当前训练流程中采用 SLERP 特征增强。在归一化特征空间中，通过对同类别样本特征执行球面插值，扩展已有样本之间的潜在特征分布，使分类器能够学习更加连续和多样化的伪造特征表示。

对于伪造类别而言，来自未知生成器的生成指纹可能表现为已有伪造模式之间的复杂组合。SLERP 增强能够在已有伪造特征簇之间补充潜在样本分布，从而提高模型面对未知伪造方式和跨来源数据时的适应能力，并在一定程度上缓解参数微调过程中的过拟合问题。

在模型训练与评估阶段，本项目在第三方 CLIP-LN checkpoint 基础上，使用 DF40 与 OpenRL/DeepFakeFace 等多来源 Deepfake 数据完成平台侧训练数据重组及参数高效微调，并完成昇腾环境下的分布式训练验证，模型从数据预处理、初始化、训练优化、模型选择、正式评估到部署应用的完整流程如图 2.7 所示。

基于 CLIP ViT-L/14 的 Deepfake 检测训练链路




图2.7 Deepfake 模型训练、评估与生产适配流程图

本次正式训练共使用 85,696 个训练样本，在 16 张昇腾 910C 上采用 BF16 混合精度进行分布式训练，全局 batch size 为 64，共训练 20 个 Epoch，并依据验证集 F1 指标选择第 6 个 Epoch 作为最终模型。独立测试集共 3,212 张图片，测试集不参与模型选择。最终 Accuracy 为 85.59%，Precision 为 83.28%，Fake Recall 为 89.04%，F1 为 86.07%。上述指标作为当前平台 Deepfake 正式能力的统一性能口径。

综上，本系统 Deepfake 检测能力形成了“Haar 人脸区域与质量前置—YuNet 五点关键点对齐—基于 CLIP ViT-L/14 checkpoint 初始化的多数据集参数高效微调模型—逐脸 Deepfake 推理—多证据决策”的完整技术链路，在保留预训练视觉模型通用表征能力的基础上，实现了对平台业务场景的适配和工程化部署。

为增强模型对未知分布（OOD）的鲁棒性，方案在分类层前对提取的特征进行了 L_2 归一化，将特征强制投影并约束至单位超球面（hypersphere）上。从几何视角分析，线性分类器在此空间下的作用类似于在超球面上分离出一个球面帽（spherical cap），有效促使模型形成紧凑的类内聚类，这也是缓解过拟合最核心的单项正则化改进。此外，方案进一步引入了均匀性（uniformity）与对齐（alignment）度量损失。均匀性损失促使特征均匀分布在单位超球面上，而与交叉熵损失的加权结合则使得同类特征簇更为紧密，从而更高效地利用了超球面空间。

在研发阶段的超球面表示分析中，先将同类特征归一化为 $\hat{h}_a$ 、 $\hat{h}_b$ ，并在当前正式训练流程中采用球面线性插值（SLERP）扩充伪造类特征。令 $\Omega = \arccos(\hat{h}_a^T \hat{h}_b)$ ， $t \sim U(0,1)$ ，则增强特征为：

$$(SLERP(\hat{h}_a, \hat{h}_b; t) = \frac{\sin((1-t)\Omega)}{\sin \Omega} \hat{h}_a + \frac{\sin(t\Omega)}{\sin \Omega} \hat{h}_b)$$

其中， $\Omega = \arccos(\text{clip}(\hat{h}_a^T \hat{h}_b, -1, 1))$

对于伪造类别而言，未知的生成器所产生的指纹往往表现为已知生成器特征的某种组合。Slerp 增强能够有效填充已知生成器特征簇之间的隐空间空白，提前让分类器适应这些多样化的未知伪造分布，起到了强大的正则化作用。

为分析各正则化组件的贡献，研发阶段比较了 LN-tuning、特征归一化、Uniformity/Alignment 与 SLERP 等策略，并通过验证集视频级 AUROC 观察长周期过拟合趋势。严格区分研发消融与正式训练配置：当前源码固定启用标签交叉熵和 SLERP 特征增强；Norm、Uniformity/Alignment 仅作为研发阶段消融项，不应写成当前生产模型必然同时启用的损失。图 2.8 用于展示研发对比趋势，当前正式发布指标仍以第 6 个 Epoch 的独立测试集结果为准。




图2.8 不同正则化组件下验证集视频级 AUROC 的迭代消融实验动态

在研发阶段，本研究结合 CLIP 的视觉先验和相关正则化策略，通过公开数据集实验观察模型跨域泛化趋势。引用 FaceForensics++、Celeb-DF-v2、DFD、DFDC、FFIW 等公开数据集上的结果，明确区分第三方论文结果、研发阶段实验

结果与当前平台正式测试结果，不将第三方或历史实验数据直接作为当前生产模型的正式准确率。当前平台最终发布指标统一以独立测试集 3,212 张样本上的 Accuracy 85.59% 和 F1 86.07% 为准。

除逐脸 Deepfake 检测外，系统同时引入通用图片真实性分析能力，用于覆盖全生成肖像、证件图以及非人脸图片等场景。该能力由生产 MLLM 输出 real/fake/uncertain 辅助证据，并与 Deepfake 检测结果共同作为真实性证据输入决策层。两者分别回答不同问题，不进行简单替代。

2.2.2 可解释性检测：MLLM 真实性分析与标准化 JSON 输出

为补充逐脸 Deepfake 模型在全生成肖像、证件图、非人脸图片及复杂视觉场景中的覆盖不足，本系统引入生产 MLLM 作为通用图片真实性分析与复杂视觉风险解释的辅助专家。需要强调的是，MLLM 输出属于独立辅助证据，不直接替代逐脸 Deepfake 检测结果，也不单独决定系统最终真实性结论。

在通用图片真实性链路中，MLLM 对输入图像输出 real、fake 或 uncertain 等辅助判断，并生成对应的结构化证据说明；在图片内容安全级联中，MLLM 还承担复杂风险场景的中文解释与证据归纳任务。其输出最终与逐脸 Deepfake、图片内容安全、来源取证及其他专家结果共同进入决策层进行多证据融合。

为提高模型输出的机器可解析性、跨模型适配能力以及后续审计稳定性，本系统设计了标准化 JSON Prompt 体系。通过 System 角色约束与 User 任务结构约束，对输出字段进行统一限定，减少自由文本格式波动带来的解析失败和归档困难。具体推理流程如图 2.9 所示。

标准输出字段主要包括：

verdict: 图片真实性辅助结论，取值为 real、fake 或 uncertain；

confidence: 当前辅助判断的置信度；

evidence: 模型识别出的视觉异常或风险证据列表；

regions: 可疑区域信息，在模型能够稳定输出空间位置时作为辅助证据使用；

explanation: 面向审核人员生成的完整中文证据说明。

上述字段仅用于结构化表达模型证据。其中，verdict 不作为系统最终真实性标签，regions 也不用于替代 Deepfake 模型的人脸区域检测结果。最终业务处置仍由决策层结合真实性、内容安全、来源取证和系统健康状态综合生成。




图2.9 MLLM 标准化证据输出流程图

在系统工程实现层面，后端封装统一的 OpenAI 兼容请求接口，可通过配置切换兼容相应接口规范的多模态模型，从而降低不同模型服务之间的适配成本。系统对模型返回内容执行结构化 JSON 解析与容错处理，在返回结果夹杂额外自然语言、换行或格式噪声时，优先提取完整 JSON 片段；当关键字段缺失或解析失败时，则返回 `uncertain` 或 `inconclusive` 状态，而不是将异常结果直接解释为真实或安全。

在证据展示层面，系统将 MLLM 输出的真实性辅助判断、视觉证据和中文解释独立展示，并与 Deepfake、图片内容安全和来源取证结果分栏呈现。不同证据回答不同问题，不将任意单一模型输出直接转换为系统最终结论。

对于需要进一步分析的高风险或争议样本，MLLM 可作为解释专家参与二次分析，但当模型超时、限流、服务不可用或无法形成可靠结论时，系统必须显式标记为 `unavailable` 或 `inconclusive`，并依赖其他专家证据或进入人工复核，不得静默降级为 `safe`。

当前平台对通用图片真实性能力采用独立辅助能力口径进行评估。现有来源代理平衡集共 60 张样本，覆盖率为 81.67%；在已形成明确判定的样本中，Accuracy 为 91.84%，F1 为 92.86%。该小规模代理集主要用于验证系统对全生成肖像、证件图和非人脸图片的辅助真实性判断能力，不代表开放世界场景下的完整准确率。其结果仅作为真实性证据的一部分，与逐脸 Deepfake 检测结果共同进入后续决策流程。

2.2.3 图片内容安全审核：轻量初筛与多专家级联

针对图片内容安全审核中单一模型难以同时兼顾推理速度、风险召回率、复杂语义理解和区域级可解释性的问题，本系统采用“轻量初筛—高召回语义二审—专项区域检测—辅助语义与文字风险分析”的多专家级联架构。不同检测组件分别承担快速筛选、复杂风险确认、成人显式区域检测以及图片文字与宽类别语义分析任务，并由统一策略层综合各专家证据生成最终处置结果，而不是将任意单一模型输出直接作为自动放行或阻断依据。整体级联结构由 MultiHeaded+Q16、PerspectiveVision-LLaVA、NudeNet、MLLM、OCR 与红线规则等组件共同组成。整体图片内容安全审核流程如图2.10所示。



图2.10 图片内容安全多专家级联检测流程

设轻量初筛输出 s_c^{fast} ，PerspectiveVision 二审输出 s_c^{pv} ，NudeNet 成人专家输出 s_c^{nude} ，MLLM/OCR/红线规则输出 s_c^{aux} 。当任一高风险类别分数超过级联阈值时进入复核：

$$s_c = \max(s_c^{fast}, s_c^{pv}, s_c^{nude}, s_c^{aux})$$

当任一高风险类别达到相应策略阈值时，样本进入进一步复核或阻断流程。该机制的核心思想是利用轻量模型提高审核吞吐量，利用高召回模型降低复杂风险漏检概率，并通过专项检测器提供区域级证据。快速模型的低风险结果不作为图片安全的充分证明，最终状态仍由策略层结合风险类别、模型分数、专家分歧及人工复核要求统一映射为 allow、review 或 block。

在第一级快速初筛阶段，系统采用 MultiHeaded 与 Q16 组成轻量视觉安全检测能力。MultiHeaded 基于 OpenCLIP ViT-L/14 提取共享图像特征，并在共享视觉表征上分别运行 sexual、violent、disturbing、hateful 和 political 五个独立二分类 MLP 检测头，以获得不同风险类别的概率。Q16 与 MultiHeaded 共享 CLIP 图像嵌入，通过归一化图像特征与预计算的安全/不安全文本提示向量进行余弦相似度匹配，形成开放词汇安全风险分数。系统进一步取各检测头和 Q16 输出中的最高风险值作为快速初筛结果。

MultiHeaded 与 Q16 使用第三方预训练权重，本项目主要完成模型本地部署、统一推理接口、风险分数融合以及平台评测。在 UnsafeBench 官方 Test 2,037 张样本的统一二分类评测中，MultiHeaded+Q16 的 Accuracy 为 71.97%、Precision 为 66.35%、Recall 为 53.80%、F1 为 59.42%，平均推理延迟约为 35.1 ms，P95 延迟约为 81.4 ms。该模型组合具有较好的推理效率，但风险召回能力相对有限，因此主要承担低延迟初筛任务，而不作为最终安全判定模型。

对于需要提高风险召回率的图片，系统进一步调用 PerspectiveVision-LLaVA 进行多模态语义二审。PerspectiveVision 以 LLaVA-1.5-7B 为基础模型，采用 CLIP ViT-L/14-336 作为视觉编码器，并加载面向内容安全任务的 LoRA 适配权重。输入图像经过视觉编码后形成视觉 Token，通过多模态投影层映射至语言模型表示空间，并结合内容安全风险定义生成 Safe/Unsafe 状态、风险类别及相关解释。

PerspectiveVision 主要用于补充轻量模型在复杂场景、隐含风险和高语义内容上的检测能力。在 UnsafeBench Test 2,037 张样本上，其 Accuracy 为 87.14%、Precision 为 78.08%、Recall 为 92.15%、F1 为 84.53%；平均推理延迟约为 809.9 ms，P95 延迟约为 1004.8 ms。由于其风险召回率明显高于轻量初筛模型，但计算开销也更高，因此系统将其定位为高召回语义二审能力，而不是对所有请求同步执行的第一层检测模型。

除整图内容安全分析外，系统引入 NudeNet 作为成人显式区域专项检测专家。平台实际采用 NudeNet 3.4.2/320n 提供的 YOLOv8n 320×320 ONNX 预训练模型，通过目标检测方式输出裸露区域的类别、置信度和边界框，而不是仅对整张图片给出 NSFW/ 非NSFW 二分类结果。

需要区分图片分类与目标检测：本系统的 NudeNet 不是对整张图片直接输出 NSFW 二分类，而是调用 YOLOv8n 目标检测网络定位成人显式区域。YOLO 为

候选位置同时回归边界框、目标置信度和类别概率；平台再通过候选阈值、非极大值抑制和显式类别白名单生成可解释的区域证据。

NudeNet 推理过程中首先将输入图片预处理至 320×320 ，模型输出候选目标区域后，以 0.2 置信度阈值完成候选框预过滤，并采用 $\text{IoU}=0.45$ 的非极大值抑制去除重复检测框。随后仅保留肛门、臀部、女性胸部、女性生殖器和男性生殖器等显式裸露类别，并以 0.6 作为平台最终业务工作点。只有属于显式裸露类别且置信度不低于 0.6 的区域才作为成人风险证据进入后续决策流程。NudeNet 的完整区域检测与后处理流程如图2.11所示，依次经过 YOLOv8n 区域检测、0.2 候选过滤、 IoU 0.45 NMS、显式裸露类别筛选和0.6业务阈值判断，最终输出区域级成人风险证据。




图2.11 NudeNet成人显式区域检测流程

当前平台未重新训练或微调 NudeNet，其作用主要是提供成人内容的区域级专项证据。现阶段验证属于模型接入和烟雾测试，非统计意义上的完整准确率评测，因此不将其与 UnsafeBench 上的二分类模型指标合并，也不虚构 Precision、Recall、F1 或 mAP 等成人专项统计指标。

在上述视觉专家之外，MLLM 用于补充复杂风险场景的宽类别语义解释，OCR 与红线规则则负责提取和分析图片中的文字风险。各专家输出作为相互独立的证据进入统一决策层。任一专家无法正常运行、输出无法解析或证据不足时，系统显式记录 inconclusive 或 unavailable 状态，并继续保留其他可用专家的检测结果，而不将专家异常静默解释为图片安全。

此外，UnsafeBench 在本系统中属于内容安全数据集、类别体系和统一评测协议，而不是一个直接部署的在线检测模型。平台采用其固定版本的官方 Test 2,037 张样本作为统一二分类评测基准，用于比较 MultiHeaded+Q16 与 PerspectiveVision 等图片内容安全能力，从而保证不同检测引擎的性能指标具有统一的数据基础和评价口径。

2.2.4 基于多专家协同与混合 RAG 的大模型安全护栏

针对大模型输入输出和 Agent 场景中存在的越狱、提示词注入、危险内容生成、敏感信息泄露以及工具滥用等风险，本系统构建由确定性规则、混合 RAG、Qwen3Guard、SingGuard、MLLM 和 XGBoost Shadow 共同组成的多专家安全护栏。不同组件分别承担确定性风险识别、政策知识检索、通用内容安全分类、Agent 专项风险分析、复杂语义解释和本地轻量分歧观测等任务，并由统一策略层完成专家编排和风险融合。

为避免检测方向与专家执行范围相互混淆，系统将二者拆分为独立参数。其中，mode 用于指定检测方向，可设置为 prompt、response 或 both，分别对应模型输入检测、模型输出检测以及输入输出双向检测；profile 用于控制专家执行范围，根据业务对延迟和风险召回能力的不同要求划分为 fast、standard 和 strict 三种运行档位。

fast 档主要执行确定性规则和 XGBoost Shadow，适用于低时延初筛及批量预检；standard 档在此基础上执行规则、RAG、Qwen3Guard、SingGuard 和 Shadow，作为默认在线安全检测模式；strict 档进一步增加 MLLM 语义二审，用于高风险内容发布和争议样本复核。通过将检测方向与专家编排档位解耦，系统可以在不改变输入/输出检测语义的情况下动态调整安全检测强度。不同运行档位下的专家编排机制如图2.12所示，系统首先根据 mode 确定检测方向，再根据 profile 选择对应的专家组合，从而实现检测方向与安全检测强度的独立控制。




图2.12 大模型安全护栏专家编排机制

确定性规则引擎首先检查越狱、提示词注入、网络攻击、武器、自伤、色情、未成年人、隐私、仇恨、违法内容及 Agent 滥用等高风险模式。对于能够通过明确关键词、结构模式或业务红线直接识别的风险，规则引擎生成确定性风险证据；对于复杂语义和隐含风险，则继续由 RAG 和模型专家进行分析。

RAG 在本系统中定位为政策与规则知识证据检索组件，而不是独立的最终安全分类器。知识库保存法规、国家标准、平台规则、内部红线材料以及相应来源和版本信息。系统采用语义向量、中文词法/字符特征和关键词规则相结合的混合召回机制，并通过融合排序、分类过滤、Top-K 和相关性阈值筛选候选知识条目。检索结果进一步返回来源文件、知识分类、分块信息、原文片段和排序依据，为风险判定提供可追溯的政策与规则证据。

需要特别区分知识检索相关性和最终内容安全风险。RAG 检索命中只表示当前输入与某项政策、规则或风险知识存在较高相关性，不能单独证明输入已经违规；RAG 未命中同样只表示当前知识库未召回足够相关的知识条目，不能据此将输入判断为安全。对于明确命中的高优先级红线规则，可以形成确定性高风险规则证据；对于仅通过语义相似度召回的潜在风险，则作为辅助证据进入其他专家分析或人工复核流程。

在图片文字风险审核场景中，系统进一步建立 OCR 与 RAG 的联动机制。图片首先通过 OCR 服务提取可见文字，审核人员可以在前端查看并修正识别结果。

进入完整审核流程时，人工修正后的 OCR 文本优先于服务端重新识别结果，并可
与审核人员手工输入的补充文本合并后送入 RAG 检索。OCR 状态、识别文本和
RAG 命中证据均进入检测报告和审计记录。当图片不存在文字、OCR 服务不可用
或没有形成可审核文本时，系统返回 empty、unavailable 或 inconclusive 等明确状
态，而不将“未识别到文字”解释为内容安全。

除规则与 RAG 外，系统进一步调用多个模型专家形成互补判断。Qwen3Guard
主要负责通用多语言内容安全、输入输出风险和越狱行为分类；SingGuard-NSFA 重
点补充 Prompt 注入、恶意代码、敏感信息窃取、危险工具调用和资源滥用等
Agent/NSFA 风险；MLLM 用于理解复杂上下文、隐含意图和宽类别风险，并以结
构化 verdict 和解释证据参与严格模式二审；XGBoost Shadow 则融合本地字符 n-
gram TF-IDF、规则、朴素贝叶斯及树模型等轻量特征，用于观察主专家之间的判断
分歧，当前不直接改变主决策结果。

对于每个风险类别 c ，规则、RAG、MLLM、Qwen3Guard 和 SingGuard 分别
输出风险证据或标准化风险分数：

$$s_c^{rule}, s_c^{rag}, s_c^{mllm}, s_c^{qwen}, s_c^{sing} \in [0,1]$$

当前系统采用保守的最高风险证据融合策略：

$$s_c = \max(s_c^{rule}, s_c^{rag}, s_c^{mllm}, s_c^{qwen}, s_c^{sing})$$

进一步定义全局风险分数：

$$S = \max_c s_c$$

统一策略层根据全局风险、具体风险类别、运行档位、专家分歧和系统状态生
成最终处置结果。该设计强调“多证据取最高风险”，避免单个第三方模型的一次
低风险输出被直接解释为绝对安全证明。对于模型分歧明显、风险处于边界区域或
涉及高影响业务决策的样本，系统进入人工复核流程。

系统同时对内容风险状态和专家运行状态进行严格区分。borderline 表示内容本
身处于风险阈值边界，需要进一步人工复核；inconclusive 或 unavailable 表示某个
专家由于证据不足、解析失败、超时或服务异常无法形成可靠结论；skipped 则表示
当前 profile 根据专家编排策略主动跳过该组件，并不代表组件发生故障。当某一专
家不可用时，系统保留其他可用专家和确定性规则的检测结果，并在专家路由轨迹
中显式记录组件执行状态，避免将系统异常静默降级为 safe。

最终，系统形成“确定性规则快速拦截—混合 RAG 提供政策证据—Qwen3Guard/SingGuard 专项分类—MLLM 复杂语义二审—多专家最高风险融合—人工复核”的大模型安全护栏链路，在兼顾在线检测效率的同时，提高复杂风险、隐含风险和 Agent 安全场景下的检测覆盖能力与判定可解释性。

2.2.5 Agent 执行安全：动作授权与轨迹审查

随着大模型逐步具备外部工具调用和实际任务执行能力，安全风险也从传统的输入输出内容审核扩展到具体动作执行过程。针对提示词注入、越权操作、敏感信息外发以及危险工具调用等风险，本系统将 Agent 安全防护覆盖至执行前、执行后和完整轨迹三个阶段，实现从内容检测到动作控制的进一步延伸。

在动作执行前，系统根据工具类型、资源范围以及写入、删除、外发、权限变更等操作属性进行确定性风险判断。对于高风险操作，系统要求使用与具体动作摘要绑定的短时一次性授权，只有通过相应授权后才允许继续执行，从而避免模型仅依据自然语言生成结果直接触发具有较大业务影响的操作。

在工具执行完成后，系统不会默认信任外部工具返回的内容，而是将其继续视为不可信数据，对其中可能存在的间接提示词注入和敏感信息进行再次检查，避免恶意内容通过工具返回结果重新进入模型后续推理过程。同时，系统对 Agent 的完整执行轨迹进行安全审查，综合分析输入、模型决策、工具调用和返回结果等过程信息。轨迹检查仅对已有内容进行回放和分析，不重新执行历史工具调用，避免审查过程产生新的副作用。Agent 从动作请求到执行后审查的完整安全控制流程如图2.13所示。系统依次进行执行前风险判断、高风险动作授权、工具执行、返回结果复检和完整轨迹审查，从而形成覆盖 Agent 实际执行过程的安全控制链路。




图2.13 Agent执行安全与轨迹审查流程

最终，系统形成“执行前风险判断—高风险动作授权—工具结果复检—完整轨迹审查”的 Agent 执行安全链路，使大模型安全防护由 Prompt 和 Response 层进一步扩展至实际工具调用过程，并为高风险操作控制、人工复核和后续安全审计提供可追溯的过程依据。

2.2.6 来源取证与水印证据链

为进一步增强 AIGC 内容检测结果的可信性与可追溯性，本系统在 Deepfake 检测、通用图片真实性分析和内容安全审核之外，引入独立的来源取证与水印证据链。该链路不将任意单一来源信号直接解释为“必然由 AI 生成”或“必然真实”，而是将文件来源、内容凭证、元数据和水印信息作为独立证据，与模型检测结果共同进入后续决策流程。

在来源取证过程中，系统首先计算上传文件的 SHA-256 哈希值，用于形成文件级唯一标识并支持后续证据一致性核验。随后通过本地 C2PA Content Credentials 解析能力读取文件中可能存在的内容凭证信息，并进一步提取 EXIF、XMP、IPTC 和 ICC 等元数据摘要，从不同层面对文件来源和处理信息进行补充分析。除标准来源信息外，系统进一步对平台侧水印信息进行核验，并将水印结果作为来源证据的一部分。最终，文件哈希、C2PA 状态、元数据摘要以及平台水印核验结果按照统一证据状态进行汇总，与 Deepfake、通用图片真实性及内容安全检测结果共同

提交后续决策和人工复核。来源取证与水印证据的完整处理流程如图2.14所示。系统依次完成文件哈希计算、C2PA内容凭证解析、元数据摘要和平台水印核验，并将不同来源证据统一汇总后提交后续决策与人工复核。



图2.14 来源取证与水印证据链流程

文件摘要按 $h_{file} = SHA - 256(file_bytes)$ 计算。C2PA 解析器在本地验证清单、资产绑定和验证状态；IPTC 仅保留字段数量、字段名和安全哈希，EXIF/XMP/ICC 仅作为元数据线索。来源状态由各证据独立汇总为 confirmed_source、not_found、inconclusive 或 invalid_or_tampered，未找到凭证不能证明文件真实，有效凭证也不能证明内容安全。

平台同时实现两类内部水印：隐式来源标记在亮度通道 8×8 DCT 块的中频系数关系中嵌入签名载荷；可逆审计水印只写入取证副本，通过 LSB/CRT 载荷与 sidecar 恢复原始像素。敏感载荷先使用 AES-256-GCM 加密，密钥再按 Shamir (2,3) 门限方案在 GF(256) 上分片，至少两份分片才能恢复。该水印只能证明“由本平台处理并绑定了审计事件”，不能冒充 Google SynthID 或 C2PA。

因此，本系统形成“SHA-256 文件哈希—C2PA 内容凭证解析—EXIF/XMP/IPTC/ICC 元数据摘要—平台水印核验—证据状态汇总”的来源取证链路。该机制通过模型检测证据与来源证据的相互补充，提高检测结果的可解释性和可追溯性，同时避免依赖单一来源信号对图片真实性作出绝对判断。

2.2.7 统一编排、降级与审计闭环

工程实现采用前后端分离与模块化服务框架。Vue 3+TypeScript+Element Plus 负责交互、证据卡和人工复核；FastAPI 负责会话鉴权、API Key/Scope、文件校验、任务编排与统一响应。完整图片审核先执行人脸前置，再通过 `asyncio.to_thread` 与 `asyncio.as_completed` 并行调度来源取证、逐脸 Deepfake、MLLM、内容安全和 OCR/RAG，使用 `POST+text/event-stream` 按完成顺序推送阶段事件。该设计让高延迟专家不阻塞其他证据返回，并允许每个组件独立扩缩容。

专家编排采用插件式路由与显式降级。确定性规则始终可用，RAG、Qwen3Guard、SingGuard、MLLM、PerspectiveVision 和 Shadow 专家按 `profile` 与配置启停；每次调用记录 `executed`、`skipped`、`unavailable` 或 `inconclusive` 以及 `latency_ms`。模块异常被封装为 `degraded/error_code`，不中断其他模块，也不把失败状态改写成低风险分数。该框架可在不改变上层 API 的情况下替换 OpenAI 兼容模型服务或新增专家。

审计层将普通运行日志与敏感证据分离：普通事件仅保存内容摘要、结果和元数据；需要保留的原始提示词、危险模型输出等证据进入 AES-GCM 加密存储。事件链使用 $h_t = \text{SHA} - 256(\text{canonical}(\text{event}_t) || h_{t-1})$ 形成前向哈希链，任何历史记录被修改都会破坏后续校验。边界样本进入人工复核队列，审核结论重新写回审计链并用于后续阈值校准和 Shadow 模型评估，形成“检测—解释—处置—复核—迭代”的闭环。

2.3 模块接口数据格式

2.3.1 MLLM 可解释输出标准 JSON格式

```
{  
  "verdict": "fake/real/uncertain",  
  "confidence": 0.0~1.0,  
  "evidence": ["伪造痕迹1", "伪造痕迹2", ...],  
  "regions": ["可疑区域1", "可疑区域2", ...],  
  "explanation": "完整中文取证分析段落"
```

```
}
```

2.3.2 全流程一体化审计报告 JSON结构

```
{  
  "task_id": "唯一任务UUID",  
  "timestamp": "检测时间",  
  "image_info": {  
    "md5": "图像哈希缓存标识",  
    "deepfake_result": {  
      "label": "fake/real",  
      "fake_score": 0~1,  
      "confidence": 0~1  
    },  
    "mllm_interpret": {  
      "verdict": "",  
      "confidence": 0,  
      "evidence": [],  
      "regions": [],  
      "explanation": ""  
    }  
  },  
  "text_audit": {  
    "matched_keywords": ["命中敏感词列表"],  
    "violated_rules": ["匹配安全红线规则"],  
    "risk_level": "high/medium/low",  
    "safe": true/false  
  },  
  "total_cost_ms": 总耗时  
}
```

2.4 红线知识库与RAG v2检索子系统

为支撑文本内容安全审核、政策依据检索和风险证据溯源，如图 2.15 所示，本系统构建了面向法规、国家标准、平台规则及内部红线的知识库与 RAG v2 检索子系统。该子系统不将知识库命中直接等同于最终违规结论，而是将检索结果作为政策与规则证据，与规则、Qwen3Guard、SingGuard、MLLM 等专家结果共同进入决策层进行多证据融合。

在知识入库阶段，系统对上传的法规、标准、平台规则和内部知识文件进行解析与结构化处理。当前采用段落和句末感知的切分策略，对于较长文本以约 500 字符为窗口，并设置约 50 字符的重叠区域，以降低标题、条款编号和上下文在切分过程中的语义割裂。每个知识切片保留来源文件、知识分类、分块编号及相关元数据，为后续原文核验和引用溯源提供基础。在知识召回阶段，系统采用语义向量检索与中文词法检索相结合的混合召回机制。语义链路基于 MiniLM 多语言向量模型，将用户查询和知识切片编码到统一语义空间；词法链路结合中文字符及双字词等局部特征，用于增强法规名称、专有词和明确红线表达的精确匹配能力。当前融合策略中，语义向量证据权重约为 70%，中文词法证据权重约为 30%。

两类检索结果通过 weighted fusion 进行统一融合排序，并结合分类过滤、Top-K 和检索阈值完成候选筛选。当前默认融合阈值为 0.32，该阈值仅用于判断知识条目是否具有足够的检索相关性，不直接对应内容安全风险等级。RAG 未命中只表示当前知识库中未召回到足够相关的条款，不能据此判定输入内容安全。

在知识召回与排序阶段，为兼顾长文本查询的语义泛化能力以及法规名称、专有词和明确红线表达的精确匹配能力，系统采用语义向量检索与中文词法检索相结合的混合召回机制。两类检索结果经过加权融合形成统一相关度评分，其核心评分函数定义为：

$$Score(q, d) = \alpha S_{vec}(q, d) + (1 - \alpha) S_{lex}(q, d)$$

其中， q 为用户查询语句， d 为候选知识切片， $S_{vec}(q, d)$ 为基于 MiniLM 多语言向量的语义相关度， $S_{lex}(q, d)$ 表示基于中文字符及双字词特征计算的词法相关度， α 为融合权重。当前系统中语义向量证据权重设置为 0.7，中文词法证据权重设置为 0.3，因此融合评分可进一步表示为：

$$Score(q, d) = 0.7 S_{vec}(q, d) + 0.3 S_{lex}(q, d)$$

系统根据融合评分对候选知识切片进行统一排序，并结合分类过滤、Top-K 和默认阈值 0.32 完成候选筛选。需要强调的是，该融合分数及阈值仅用于知识检索相关性判断，不直接代表内容安全风险概率，也不能单独作为最终违规判定依据。



图2.15 红线知识库与 RAG v2 混合检索架构图

2.5 软硬件环境部署要点

本系统采用“正式主站 + RTX 4090 专家节点 + 昇腾 910C 实验/训练节点”的异构部署方式。正式主站负责 HTTPS 接入、前后端服务、业务编排、规则、RAG、数据库、审计、开放 API 和驾驶舱；RTX 4090 节点部署 Qwen3Guard、SingGuard、PerspectiveVision 等模型专家；昇腾 910C 节点主要用于 Deepfake 模型训练、推理验证及国产化适配实验，不作为正式生产主链的硬依赖。后端基于 FastAPI，前端采用 Vue3、TypeScript 和 Element Plus，各模型服务通过标准接口独立接入，便于模型升级、故障隔离和资源扩展。项目早期使用的 Intel i7-12700H、16GB 内存及 RTX 3060 环境仅作为开发与局部实验配置。

第三章 作品测试与分析

为全面验证系统的可靠性与业务实用性，本研究构建了覆盖底层核心算法与全端工程链路的多维评估体系。该体系由模型泛化验证、本地推理验证、内容安全审核及工程性能测试四个核心环节构成，整体评估流程如图 3.1 所示。



图3.1 系统多维评估体系与实验流程设计

为确保评测的科学性与结论的可信度，平台在测试过程中确立了以下数据使用与结果解释原则。

首先，所有训练集、验证集与测试集均严格隔离，并按视频、身份及数据来源进行分组切分，以避免同一视频或同一身份的相邻帧跨越不同集合，从源头降低数据泄漏风险。验证集仅用于模型选择与阈值确定，独立测试集则作最终性能报告，全程禁止使用测试集反复调参，防止产生乐观偏差。

其次，不同任务各自独立评测——Deepfake 检测、图片内容安全、文本护栏与通用图片真实性分属不同问题域，各项指标不合并为所谓的“系统总准确率”。对于缺乏真实标签的数据，仅报告预测分布，不计算准确率、召回率或 AUC；代理数据集（如 Lexica 与 Laion5B 的固定来源样本）仅用于验证链路可行性，其结论不外推为通用世界的全域准确率，亦不代表模型对所有生成模型、压缩格式或真实业务图片的普适能力。

最后，高风险决策采用多级审核机制：模型输出主要用于辅助识别、二审及人工复核，任何单一模型结果均不直接触发自动执法或自动封禁，确保最终处置始终保留人工判断与干预空间。

3.1 测试环境与总体方案

表 3.1 与表 3.2 分别列举了本次实验所依托的硬件配置与软件组件版本。

表3.1 测试环境硬件配置

配置项	规格
CPU	Intel Core i7-12700H
GPU	NVIDIA RTX 3060 (6GB)
内存	16GB DDR5
操作系统	Windows 11

表3.2 测试环境软件配置

组件	版本
Python	3.11
PyTorch	2.2.0
FastAPI	0.110.0
Vue	3.4.0
ChromaDB	0.4.22

说明：表3.2记录本报告对应实验阶段的冻结软件环境，用于保证当时结果可复核；当前平台在后续维护中已升级部分依赖版本（例如FastAPI、ChromaDB、Vue/Vite和Element Plus）。

软件环境方面，后端采用 FastAPI 0.110.0 ，前端使用 Vue3 4.0 ，向量数据库为ChromaDB 0.4.22 ，所有依赖均通过 pip 和 npm 统一管理。

作品测试覆盖的主要任务如表3.3 作品测试任务与数据划分所示。

表3.3 作品测试任务与数据划分

测试任务	数据集与规模	标签状态	主要用途
本平台 Deepfake 检测	训练样本 85,696 张；验证集 3,212 张；独立测试集 3,212 张	真实/伪造	训练、选轮次、最终性能报告
图片内容安全	UnsafeBench Test, 2,037 张，其中安全 1,260 张、风险 777 张	安全/风险	比较轻量初筛模型与高召回二审模型
Agent 护栏	NSFA Cross-source Query Multilingual, 3,435 条	风险	复测 SingGuard 文本安全分类能力
通用图片真实性	Lexica 30 张 + Laion5B 30 张	来源（不等于全域真值）	验证 real/fake/uncertain 链路及覆盖率
XGBoost Shadow	交付题库 3,663 条；独立测试 732 条	基于 Excel 颜色、表名形成准标签	旁路分歧发现，不作为主模型
正式站人工回放	208 条人工标注记录，其中 206 条有可比较输出	人工复核	检验 Shadow 模型域外稳定性
NudeNet 成人专项	8 张业务负样本 + 1 张官方正样本	烟雾测试样本	验证区域检测链路，不发布统计准确率

表 3.3 中各测试任务的标签质量、样本规模和评测协议各不相同，后续报告中的指标均严格对应各行用途，不做跨任务合并或外推。

3.2 评测指标与测试方法

对于二分类任务设： TP 为风险样本正确检出； TN 为安全样本正确放行； FP 为安全样本误报； FN 为风险样本漏报。

主要指标定义如下：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}$$

此外，作品还关注：

误报率：

$$FPR = \frac{FP}{FP + TN}$$

漏报率：

$$FNR = \frac{FN}{FN + TP}$$

覆盖率：

$$Coverage = \frac{N_{\text{确定输出}}}{N_{\text{总样本}}}$$

ROC-AUC、PR-AUC：仅在样本具有完整标签且模型输出连续分数时计算；

ECE、Brier Score：用于辅助分析概率校准；

P50/P95 延迟：分别表示请求端到端耗时的 50% 和 95% 分位点。

需要说明的是，图片真实性模块允许输出 `real`、`fake` 或 `uncertain`。因此，该模块除已判定样本上的分类指标外，还单独报告覆盖率，避免将拒绝判断的样本强行纳入二分类准确率。

3.3 Deepfake 检测测试与分析

3.3.1 训练配置与资源

Deepfake 正式训练采用 DF40 train 与 OpenRL/DeepFakeFace train 作为训练数据，共计 85,696 个训练样本，另设验证集与独立测试集各 3,212 张，按视频/身份/来源分组切分以防止数据泄漏。模型以第三方 CLIP-LN checkpoint 为初始化，在本平台完成数据重组、参数高效微调（仅更新 LayerNorm 与分类头）、分类头训练、模型评估和推理集成。

如表3.4 所示，训练环境为 16 张 Ascend 910C NPU，采用 HCCL 分布式数据并行（DDP），BF16 混合精度，每卡 batch size 为 4，全局 batch size 为 64，共训练 20 个 epoch。

表3.4 Deepfake 正式训练配置

项目	配置
训练数据	DF40 train + OpenRL/DeepFakeFace train
训练样本数	85,696
验证集	3,212 张
独立测试集	3,212 张
训练设备	16×Ascend 910C
并行方式	HCCL DDP
训练精度	BF16
每卡 Batch	4
全局 Batch	64
训练轮数	20 epoch
选模轮次	epoch 6
选模指标	验证集 F1
模型哈希	fd0b967e9ab6a19aa0127c5c2301b3883ff8013b1a5d7af282e29737132c1fb9

训练总墙钟时间为 2,783.192 秒，约 46 分 23 秒。训练损失在前 3 个 epoch 下降较快，第 6 个 epoch 达到记录中的最低值 0.369105，后续基本在 0.369-0.370 区间波动。由于训练损失不能充分反映跨域泛化能力，最终按照验证集 F1 选择 epoch 6。

3.3.2 独立测试集结果

独立测试集共 3,212 张，混淆矩阵为：TP = 1,430；TN = 1,319；FP = 287；FN = 176。

表3.5 Deepfake 验证集与独立测试集结果

数据划分	TP/TN/FP/FN	Accuracy	Precision	Recall	F1	推理耗时
验证集	1481 / 1350 / 256 / 125	88.14%	85.26%	92.22%	88.60%	26.758
独立测试集	1430 / 1319 / 287 / 176	85.59%	83.28%	89.04%	86.07%	32.730

如表3.5 所示，独立测试集相较验证集的 F1 下降为 2.53 个百分点。该结果表明模型具有较好的伪造图像识别能力，但仍存在一定程度的域偏移。为避免夸大性能，作品正式展示和参赛报告以独立测试集结果为主，验证集结果仅用于说明选模过程。

3.3.3 与基线 and 不同训练协议的比较

如图 3.2所示与第三方原始基线相比，正式模型（多数据集，16卡，epoch 6）取得如下提升：

Accuracy 提升 13.61 个百分点 (71.98% → 85.59%) ;

Fake Recall 提升 42.82 个百分点 (46.22% → 89.04%) ;

F1 Score 提升约 0.238 (0.623 → 0.861) 。

结果分析:

多来源训练显著增强了模型对伪造样本的识别覆盖能力,有效缓解了原始基线模型漏检率过高的问题。与此同时, Precision 从 95.34% 降至 83.28%,表明模型在大幅提升风险召回率的过程中,不可避免地引入了一定数量的误报。

从实际业务视角来看,这一权衡符合"高风险场景优先降低漏报"的原则。在 Deepfake 检测场景中,漏检(放过伪造内容)的代价通常远高于误报(将真实内容标记为可疑)。然而,误报率的上升仍可能对用户体验和运营效率造成负面影响,因此后续将通过以下手段进行精细化管控:

1. 动态阈值策略:根据业务场景的风险等级设置差异化判定阈值;
2. 人工复核机制:对模型输出的高风险样本建立二级审核流程;
3. 持续校准优化:基于线上反馈数据迭代训练,逐步压缩误报空间。

此外,对比中间方案(DF40-only, 4卡 HCCL, 一轮训练)可见,扩大训练数据规模和算力投入是 Fake Recall 与 F1 显著提升的关键驱动因素,而非单一数据源的简单调优所能替代。




图3.2 Deepfake 不同模型协议对比图

3.3.4 五折交叉检验

为系统评估模型结果的稳定性与泛化能力，本研究基于同一总数据池实施分组五折交叉检验（5-Fold Cross-Validation）。具体设置如下：

- 每折训练样本：约 68,000 张
- 每折验证样本（held-out）：约 17,000 张
- 独立 checkpoint 数量：5 个

表3.6 Deepfake 五折交叉检验结果

指标	Mean ± SD
Accuracy	83.81% ± 0.29%
Precision	88.48% ± 0.29%
Fake Recall	77.73% ± 0.81%
Specificity	89.88% ± 0.32%
F1	0.8276 ± 0.0040

表3.7 不同子集上的表现

子集	F1(Mean±SD)
DeepFakeFace	0.8282 ± 0.0054
DF40	0.8263 ± 0.0077

训练稳定性优异：如表3.6 所示，五折交叉检验各指标的标准差较小（Accuracy 与 Precision 约 ±0.29%，F1 约 ±0.0040），说明不同数据划分下的结果较为一致。但交叉检验只能支持划分稳定性判断，不能单独证明不存在过拟合；是否过拟合仍需结合独立测试集、跨生成器测试和训练曲线综合判断。

子集间泛化均衡：如表3.7所示，DeepFakeFace 子集与 DF40 子集的 F1 分别为 0.8282 与 0.8263，差异仅 0.0019，且两者均围绕整体均值（0.8276）小幅波动。这表明模型对两类典型伪造数据源的识别能力较为均衡，未出现对特定生成技术的显著偏向。

正式模型使用固定的 85,696 张训练样本，而五折每折约使用总数据池的 80%；因此两种协议在训练样本规模、分组方式和选模流程上并不完全相同。

五折交叉检验在于验证模型训练过程的稳定性与结果的可复现性。因此，五折结果作为模型可靠性的支撑证据，正式模型的最终性能仍以独立测试集结果为准。

3.3.5 跨生成器外部测试

为进一步验证模型对未参与训练的外部生成器的泛化能力，本研究在两类独立来源上开展了 fake-only 测试。由于测试集仅包含伪造样本，无法计算Accuracy、Specificity 及完整混淆矩阵，故以 Fake Recall 作为核心评估指标。

表3.8 跨生成器外部测试结果

外部来源	样本数	基线 Fake Recall	Epoch 6 Fake Recall	提升
Inpainting	30,000	36.17%	76.76%	+40.59 pp
InsightFace	30,000	51.15%	69.32%	+18.16 pp

注：pp = percentage points（百分点）

整体迁移能力显著：模型对两类外部生成器均展现出明显的正向迁移效果。跨生成器外部测试结果见表3.8。其中，Inpainting 来源的 Fake Recall 从 36.17% 大幅提升至 76.76%（+40.59 pp），提升幅度接近 InsightFace 的两倍，说明模型对图像修复类伪造痕迹的学习具有较好的外推性能。

生成器间存在性能差异：如图3.3 所示，尽管模型对两类来源均有提升，但 InsightFace 的最终召回率（69.32%）仍低于 Inpainting（76.76%），且其基线水平本身就更高（51.15% vs 36.17%）。这一现象表明：**生成器差异：**不同伪造技术的底层生成机制（如基于 GAN 的面部替换 vs 基于扩散模型的图像修复）会导致伪造痕迹的分布特征显著不同；**图像质量影响：**InsightFace 生成的伪造图像在视觉逼真度上可能更高，导致伪造痕迹更隐蔽，模型识别难度更大；**训练数据覆盖度：**训练集中对 InsightFace 类生成技术的样本覆盖可能相对不足，限制了模型的泛化边界。

跨生成器测试揭示了模型在面对未知伪造技术时的能力边界。将在后续迭代中持续扩充训练数据的生成器多样性，并针对低召回来源（如 InsightFace）进行专项数据增强或模型微调，以进一步压缩迁移差距。



图3.3 跨生成器外部测试对比图

3.3.6 昇腾 910C 工程验收与性能测试

本部分测试旨在验证平台在国产异构算力（昇腾 910C NPU）上的训练可行性、推理兼容性与工程稳健性，同时完成系统级验收测试，确保模型可部署于非 GPU 环境。实验分层设计，由低到高逐步增加负载，并保留完整的性能与正确性证据。

3.3.6.1 NPU 热核微基准测试与真实推理性能

为验证底层软硬件环境及多卡协同计算能力，我们在 CANN 8.5.1、torch-npu 2.9.0.post1 和 vLLM-Ascend 环境下，使用编号为 2、3、4、5 的四张物理卡进行了微基准测试。测试任务包含 4096×4096 的 FP16 矩阵乘法以及 4096-4096-4096 的多层感知机（MLP）计算，每台设备的批处理大小（Batch Size）设为 32。

表3.9 四卡 NPU 热核微基准

物理卡	矩阵TFLOPS	MLP平均延迟	MLPP95	吞吐 (samples/s)
卡 2	307.999	0.108 ms	0.144 ms	296,036.08
卡 3	297.271	0.098 ms	0.116 ms	324,964.87
卡 4	306.148	0.108 ms	0.119 ms	296,394.49
卡 5	306.116	0.110 ms	0.127 ms	290,301.14
四卡合计	1,217.534	—	—	1,207,696.58

如表3.9所示，四卡总墙钟时间为 11,652.747 ms，矩阵计算合计 1,217.534 TFLOPS，MLP 推理吞吐合计 1,207,696.58 samples/s。结果表明，当前 NPU 环境下矩阵计算与 MLP 推理性能稳定，四卡并行无明显异常，为后续真实大模型推理提供了硬件与框架层面的可用性支撑。

表3.10 真实 Qwen 推理验证结果

指标	结果
HTTP 状态码	200
输入 tokens	57
输出 tokens	64
总 tokens	121
端到端延迟	~2,682 ms
safe 延迟	3,917 ms
borderline 延迟	1,921 ms
unsafe 延迟	3,009 ms
平均延迟	~2,949 ms

如表3.10所示，真实 Qwen 推理，复用已有 vLLM-Ascend 服务（Qwen3-235B W8A8），对中文安全样本进行三类分类（safe/borderline/unsafe）。一次典型请求耗时 2,682 ms（输入 57 tokens，输出 64 tokens），三类样本平均延迟 2,949 ms，输出结果与预期一致（但在未启用 JSON mode 时可能含思考文本，需经解析器归一化）。该实验证明昇腾 910C 可承载大模型推理，且可集成至平台护栏（需配合校验与降级机制）。

3.3.6.2 Deepfake 候选微调过程

候选微调（单卡/四卡独立）用于验证 NPU 上的反向传播和checkpoint保存。在 DF40 test 上，候选版相比第三方基线（F1=0.623）提升至 0.786，Fake Recall 从 46.22% 提升至 75.03%（表 3.15），证实微调链路在 NPU 上的正确性。

表3.11 910C 候选微调与基线对比（DF40 测试集）

模型与划分	Accuracy	FakeRecall	Precision	F1	混淆矩阵
第三方基线 / DF40 test	71.98%	46.22%	95.34%	62.3%	TP=696, TN=1472, FP=34, FN=810
4卡 HCCL / DF40 test	81.79%	74.10%	87.56%	80.3%	TP=1190, TN=1437, FP=169, FN=416

模型与划分	Accuracy	FakeRecall	Precision	F1	混淆矩阵
候选微调 / DF40 val	87.89%	90.47%	86.03%	88.2%	TP=1453, TN=1370, FP=236, FN=153
候选微调 / DF40 test	79.51%	75.03%	82.42%	78.6%	TP=1205, TN=1349, FP=257, FN=401

如表3.11 所示，相对第三方基线，候选版在 DF40 test 上 Fake Recall 提升 28.81 个百分点，F1 提升 0.163，但误报增加。

3.3.6.3 16卡正式训练与多数据集结果

正式训练使用 DF40 train 与 OpenRL/DeepFakeFace train，共 85,696 张训练样本，20 epoch，16×Ascend 910C，BF16，最佳 epoch=6。DF40 curated held-out 验证集与独立测试集各 3,212 张，阈值 $\tau = 0.5$ 。验证集用于选择轮次，独立测试集仅用于最终报告。验证集与独立测试集结果见表3.12。

表3.12 验证集与独立测试集结果

数据集/split	样本数	TP/TN/FP/FN	Accuracy	Precision	Recall	F1	耗时/s
验证集（选 epoch）	3,212	1481/1350/256/125	88.14%	85.26%	92.22%	88.60%	26.758
独立测试集（最终报告）	3,212	1430/1319/287/176	85.59%	83.28%	89.04%	86.07%	32.730

如表 3.12 所示，验证集 F1 到独立测试集 F1 的下降为 2.53 个百分点，表明模型存在一定的域偏移，但仍在可接受范围内。为进一步剖析模型的收敛行为与训练效率，图 3.4 与图 3.5 分别给出了 20 轮训练过程中的损失曲线、学习率调度以及每轮计算耗时。




图3.4 16 卡 20 轮训练 Loss、学习率与 epoch 6 选模标记

图 3.4 展示了16卡昇腾 910C 上 20 轮训练的交叉熵损失与学习率变化轨迹。训练损失在第 1 至第 3 轮快速下降，随后进入平缓波动区间，表明模型在约 3 轮后即完成主要特征适配。学习率采用余弦退火策略从 8×10^{-5} 衰减至 5×10^{-5} ，维持了后期训练的稳定性。值得注意的是，第 6 轮（Epoch 6）验证集 F1 达到峰值（对应损失值为 0.369），因此被选定为生产检查点；第 7 轮后损失虽在低位震荡但未见进一步优化。




图3.5 16 卡 每轮墙钟耗时与累计训练时间

训练的计算效率如图 3.5 所示。在 16 张昇腾 910C NPU 上，每轮平均墙钟耗时为 137.1 秒，且各轮次间的耗时波动极小（标准差约 1.5 秒），表明 HCCL 分布式通信与数据加载未出现明显拥堵或资源争抢。累计训练时间呈线性增长，20 轮总计耗时 2,783 秒（约 46 分 23 秒）。该线性度证明多卡扩展在训练规模上具有良好的可预测性，为后续在国产算力集群上扩展至更大数据集提供了可行性参考。

3.4 图片内容安全测试

3.4.1 UnsafeBench 统一测试

为系统评估不同模型在图片内容安全检测任务上的性能与效率权衡，本研究在 UnsafeBench Test 的 2,037 张测试图片上，对轻量初筛模型（MultiHeaded+Q16）与重载二审模型（PerspectiveVision）进行了对比实验。具体测试结果如下表3.13 所示。

表3.13 UnsafeBench 测试结果

模型	TP/TN/FP/FN	Accuracy	Precision	Recall	F1	P95延迟
MultiHeaded + Q16（初筛）	418 / 1,048 / 212 / 359	71.97%	66.35%	53.80%	59.42%	81.4 ms
PerspectiveVision（二审）	716 / 1,059 / 201 / 61	87.14%	78.08%	92.15%	84.53%	1,004.84 ms

轻量初筛模型：速度优先，召回受限。MultiHeaded + Q16 的核心优势在于极低推理延迟（P95 ≈ 81.4 ms），能够满足高并发场景下的实时处理需求，适合作为大规模内容审核的第一道防线。然而，其 Recall 仅为 53.80%，意味着近半数的不安全内容可能被漏检（FN = 359），漏报风险显著，因此不宜单独承担自动放行决策任务。

重载二审模型：高召回，但存在效率与精度瓶颈。PerspectiveVision 在 Recall（92.15%）与 F1（84.53%）上显著优于轻量模型，漏检数量从 359 降至 61，体现了强大的风险覆盖能力。PerspectiveVision 更适合作为保守型二审模型，对初筛输出的风险样本进行深度复核，而非独立承担全自动化执法。

3.4.2 NudeNet 专项检测边界

为验证成人内容专项检测模块的功能链路部署可行性，本研究设计了小规模边界实验。需要特别说明的是，受限于当前缺乏合规冻结的成人专项统计测试集，本实验仅用于功能验证与性能基线测定，不发布 Precision、Recall、F1 或 Accuracy 等统计指标，亦不与 UnsafeBench 的 2,037 张二分类评测数据混合解读。相关测试数据如表3.14 所示。

表3.14 NudeNet 专项检测结果

实验类型	样本	结果	结论
正常业务链路验	8 张	8/8判定为not_detected	证明链路可用，但样本量有

实验类型	样本	结果	结论
证	(驾照及合成业务样本)		限，不能代表总体准确率
官方正样本烟雾测试	1 张 (官方显式成人正样本)	检出 3 个敏感区域，最高置信度0.8555	证明专项检测模块能够正确触发，具备基础检测能力
性能基准测试	本地 ONNX Runtime	首次加载约465 ms；热启动约41–48 ms/张	CPU 可运行，无需独占 GPU/NPU，部署门槛低

实验局限性说明：

样本规模限制：正常业务链路仅 8 张样本，无法支撑统计显著性检验；正样本烟雾测试仅 1 张，仅用于功能触发验证；

缺乏标准基准：当前无公开、合规且规模化的成人内容检测基准数据集，导致无法与业界模型进行公平对比；

NudeNet 实验结果仅证明技术链路可运行、模块可触发、性能可接受，后续将在在获得合规数据集后开展大规模统计评估。

3.5 Agent 护栏测试（SingGuard NSFA）

为评估 SingGuard 在 Agent 文本内容安全场景下的防护能力，本研究基于 NSFA Cross-source Query Multilingual 数据集开展复测。该数据集包含 3,435 条多语言样本，涵盖提示注入（Prompt Injection）、恶意代码生成、敏感信息窃取等典型高风险请求类型，能够有效检验模型在跨语言、跨攻击来源场景下的泛化性能。

表3.15 SingGuard 测试结果

指标	结果
Accuracy	81.98%
Precision	79.92%
Recall	97.84%
F1	87.98%
平均延迟	28.78 ms
P50 延迟	26.89 ms
P95 延迟	40.05 ms

注：测试混淆矩阵为：TP = 2,265、TN = 551、FP = 569、FN = 50。

结果分析：

召回率优异，高风险拦截能力强：如表3.15所示，SingGuard 的 Recall 达到 97.84%（FN = 50），意味着在 2,315 条实际风险样本中，仅 50 条未被成功拦截。这一指标表明模型对提示注入、恶意代码、敏感信息窃取等高风险请求具有极强的识别与拦截能力，能够有效阻断绝大多数攻击链路，降低 Agent 被恶意利用的风险。

精确率存在提升空间，误报需关注：Precision 为 79.92%（FP = 569），即约有 20% 的正常请求被误判为风险。误报主要集中在以下场景：多语言语义边界：跨语言表达的细微差异可能导致模型对中性请求产生过度敏感；跨来源风格差异：不同数据源的攻击模式分布不均，模型对某些来源的正常样本存在先验偏见；边界语义模糊：部分请求在"创意探索"与"恶意诱导"之间的界限模糊，模型倾向于保守判定。因此，本平台不将SingGuard 的单一输出直接作为最终处置依据，而需将其纳入多层决策体系中进行综合研判。

推理延迟满足实时性要求：平均延迟 28.78 ms、P95 延迟 40.05 ms，均处于实时级响应区间（< 50 ms）。这意味着 SingGuard 能够在不显著增加用户感知延迟的前提下，完成每次请求的实时预检，适合部署于高并发的在线推理链路中。

3.6 通用图片真实性测试

3.6.1 代理数据集测试结果

为评估当前图片真实性鉴定链路的基础可用性，本研究采用固定来源的平衡代理数据集进行测试。该数据集共计 60 张样本，包含 30 张由 Lexica 生成的 AI 图像（正样本）与 30 张取自 Laion5B 的自然图像（负样本）。在推理过程中，模型输出被设定为三种离散状态：真实（Real）、伪造（Fake）与不确定（Uncertain）。

在总计 60 张测试样本中，模型给出确定性预测（即判定为 Real 或 Fake）的样本为 49 张，其余 11 张输出为 Uncertain。整体预测覆盖率（Coverage）为 81.67%。针对 49 张确定输出的样本，其混淆矩阵统计为：真阳性（TP）= 26，真阴性（TN）= 19，假阳性（FP）= 3，假阴性（FN）= 1。具体性能与延迟指标如表 3.16 所示。

表3.16 基于代理数据集的通用图片真实性测试结果

指标	结果
总样本数	60
确定输出数	49

指标	结果
不确定数	11
覆盖率（Coverage）	81.67%
已判定样本 Accuracy	91.84%
Precision	89.66%
Recall	96.30%
F1	92.86%
平均延迟	20.02 s
P95 延迟	26.46 s

从已判定的样本表现来看，模型在该代理数据分布上展现出了较高的识别准确度。同时，约 18.33% 的样本被归为“不确定”状态，表明模型具备对低置信度样本的拒绝判断机制。该机制在实际业务中具有重要意义，能够有效规避因强制分类而导致的误判风险，尽管这在一定程度上会折损系统的整体覆盖率。

3.6.2 无真值盲测边界

为进一步探究模型在未知分布下的预测倾向及系统底层运行效能，本研究在 FaceForensics 公开的 Unseen Benchmark 数据集上进行了盲测验证。该测试子集包含 1,000 张未提供官方真实标签（Ground Truth）的图像样本。由于该数据集没有可验证的官方标签，因此不计算 Accuracy、Precision、Recall、F1 或 ROC-AUC。该实验仅用于观察模型预测分布和运行性能。测试输出统计如表3.17 所示。

表3.17 FaceForensics 无真值数据集盲测分布与吞吐性能统计

统计量	结果
平均 p_fake	0.1668
中位数 p_fake	0.0933
预测为 fake	91 张（9.1%）
预测为 real	909 张（90.9%）
GPU 推理总耗时	30.015 s
推理吞吐	33.32 images/s

本实验的核心目的在于观测模型在无监督开放环境下的输出分布特性与工程化性能。测试结果表明，模型在此类无真值基准集上整体呈现出符合预期的低伪造判

定倾向（仅约 9.1% 的样本被预测为伪造），且系统在批量处理任务中具备稳定、高效的图像吞吐能力。

3.7 XGBoost Shadow 旁路测试

3.7.1 模型定位与配置

XGBoost Shadow 是文本护栏的本地旁路观察模型，接收与主护栏相同的文本输入，但其结果不参与最终的 `safe`、`borderline` 或 `unsafe` 决策。其主要作用包括：现主护栏与本地模型的分歧；定位规则系统的潜在盲区；记录不同风险类型下的置信度差异；为人工复核和后续重训提供样本；在主护栏不可用时保持旁路可选，不影响主链路运行。

模型使用文本统计特征、规则命中特征、字符 2—4 gram TF-IDF 近邻特征以及八组主题指示特征。正式模型采用 XGBoost `binary:logistic`，主要参数如表 3.16 所示。

表3.18 XGBoost Shadow 主要参数

参数	设置
目标函数	<code>binary:logistic</code>
<code>eta</code> （学习率）	0.08
<code>max_depth</code>	4
<code>subsample</code>	0.9
<code>colsample_bytree</code>	0.9
<code>random seed</code>	42
训练轮数	180

如表3.18 所示正式部署的模型采用 XGBoost 算法，目标函数设定为 `binary:logistic`（二分类逻辑回归）。其核心超参数配置如下：学习率（`eta`）= 0.08，最大树深（`max_depth`）= 4，样本子采样率（`subsample`）= 0.9，列采样率（`colsample_bytree`）= 0.9，随机种子（`seed`）= 42，迭代训练轮数设定为 180 轮。

3.7.2 正式站人工标注回放

为评估模型在真实业务分布下的实际表现，本研究从正式生产环境中抽取了 208 条经人工精细标注的回放数据进行对比测试，其中 206 条具备有效且可比对的 Shadow 模型输出结果。具体评估指标与混淆矩阵统计如表 3.19 所示。

表3.19 XGBoost Shadow 正式站人工回放结果

指标	结果
可比较样本数	206
TP	74
TN	63
FP	29
FN	40
Accuracy	66.50%
Precision	71.84%
Recall	64.91%
F1	68.20%

如表3.19 所示，在 206 条可比较样本中，FN = 40（实际风险但预测为安全），FP = 29（实际安全但预测为风险）。漏检与误报数量接近，说明模型在真实分布上的判别边界模糊，对以下场景尤为敏感：语义边界模糊的提示注入（如伪装成正常指令的间接攻击）；多语言混合表达中的风险特征弱化；短文本因特征稀疏导致的预测不稳定。

因此，本作品将 XGBoost 固定为 Shadow 观察模型，不将其作为生产主审核器，也不允许其覆盖主护栏的最终判断。该设计一方面保留了旁路模型在风险发现、样本积累和规则盲区定位方面的价值，另一方面避免其因域偏移导致的误判影响主链路安全决策。

3.8 与同类产品对比分析

3.8.1 图片内容安全对比

1.主流云厂商内容审核服务

腾讯云 IMS（图片内容安全）默认 QPS 100 次/秒，支持万级动态扩容，单张图片审核耗时约 800 ms，服务可用性承诺 99.9%。阿里云内容安全图片检测（排除下载时间）约 300 ms，同步检测最长允许 6 秒。两者均支持涉黄、暴恐、违法等核心场景识别。

公开厂商资料和产品文档通常会给出腾讯云 IMS、网易易盾、数美科技等产品的吞吐或测试指标；由于本文未在统一公开数据集、统一阈值和统一硬件上复现实

验，以下数字仅作为公开资料中的参考口径，不作为与本平台的严格精度排名。例如，相关资料中曾报告网易易盾在特定10万张测试集上的识别准确率为99.87%、数美科技为99.62%，其数据集、标注和测试条件需以原报告为准。




图 3.6 腾讯云内容安全操作视图

2. 专用内容审核 API

Sightengine 标称响应时间低于 100 ms，支持 110+ 类别（含裸体、仇恨、毒品等），定价 \$29/月含 10,000 次操作。Hive Moderation 的视觉语言模型（11B 参数）专为内容审核优化，月处理量达数十亿张图片。在延迟对比中，Sightengine 约 350-380 ms，Hive Moderation 约 450 ms（P95 延迟 Sightengine 750 ms）。

3. 本平台定位

本平台 PerspectiveVision 在 UnsafeBench Test 2,037 张上 Recall 达 92.15%、F1 84.53%，平均延迟 809.9 ms、P95 1004.8 ms（表 3.13）。与腾讯云 IMS（~800 ms）和阿里云（~300 ms）相比，本平台延迟略高，但 Recall（92.15%）在内容安全场景中具有优势——高召回意味着更少的违规内容漏报。与专用审核 API

（Sightengine 标称 <100 ms）相比，本平台基于 7B 多模态大模型，语义理解能力更强，能够处理非显式风险（如隐含意图、语境敏感内容），而不仅限于关键词和表面特征匹配。

本平台的核心差异化在于：**证据可解释**（输出风险类别、证据片段和模型解释）和**可本地部署**（不依赖第三方 API，数据不出域），这在政企、金融等数据敏感场景中具有独特价值。

3.8.2 推理性能与部署成本对比

1.昇腾 910C 推理性能

据公开研究报告，华为昇腾910C在特定推理任务上的性能可达NVIDIA H100的约60%；报告中的CloudMatrix384、DeepSeek-R1和量化配置属于其特定软硬件环境，不能直接等同于本文平台的实测结果。本文仅将其作为国产算力背景参考，并单独报告本平台910C实验数据。

在 INT8 量化下，Atlas A2 平台可保持 90% 以上的 FP16 精度，同时实现最高 1.5 倍的推理加速。

2.本平台 910C 实测

本平台 16 张昇腾 910C 完成 85,696 张样本、20 轮正式训练，总墙钟 2,783 秒（约 46 分钟），平均每轮 137 秒（图3.5）。四卡 NPU 热核基准验证了 CANN 栈和卡间通信能力：矩阵计算合计 1,217.5 TFLOPS，MLP 推理吞吐合计 1,207,696 samples/s（表3.9）。真实 Qwen 推理单次请求耗时 2,682 ms（输入 57 tokens，输出 64 tokens）（表3.10）。

表3.20 部署成本对比

对比维度	商用 API (如 Hive/Sightengine)	NVIDIA GPU 自部署	昇腾 910C 自部署
推理延迟	100 ms - 数秒（视服务商）	取决于模型	与 GPU 可比
推理吞吐	受 QPS 限制	高	可达 H100 60%
数据主权	数据离开本地	本地	本地
硬件成本	按调用量付费	GPU 采购价高	国产化，成本可控
供应链风险	依赖外部服务	依赖 NVIDIA 供应	无外部依赖

如表3.20 所示，本平台已完成 910C 从候选微调到 16 卡分布式训练的完整验证，证明国产 NPU 可承载生产级 Deepfake 训练与推理任务，为数据敏感场景提供了不依赖外部算力的可行路径。

3.8.3 综合定位与差异化分析

本平台定位为“可私有化部署的 AIGC 安全运营基础设施”，在以下维度形成差异化：

表3.21 综合分析对比

维度	学术SOTA	商用API	本平台
检测精度	极高（域内 97%+）	高 （商用最优）	中等偏高 （跨域 86% F1）
跨域泛化	弱（域内↔跨域差距大）	中等	较强 （多数据集微调）
可解释性	弱（多为黑盒）	弱 （API不透明）	强（证据链 + 解释）
数据主权	本地	云端 （数据外传）	本地
人工复核闭环	无	部分提供	完整（已验证）
国产 NPU 适配	无	无	已完成（910C 验证）
来源取证 （C2PA）	无	少数提供	已集成

如表3.21所示，在本文收集的对比口径中，学术SOTA报告的域内结果高于本平台独立测试结果；本平台在当前多数据源训练和固定测试协议下取得86%量级F1。由于双方数据、训练协议和评测设置并不完全一致，不能据此宣称跨域性能全面优于学术SOTA；本文仅将其作为定位和差异化讨论。

在可解释性与来源取证（C2PA）方面，本平台重点提供商用API或纯算法模型通常不包含的证据展示能力：输出模型理由、证据链、元数据哈希和C2PA状态，形成可审计结果。该差异是功能定位上的比较，不代表在统一精度或法律效力评测中全面优于其他方案。

在数据主权、人工复核闭环和国产 NPU 适配三个工程维度上，本文已完成本次部署与测试协议要求的验证：本地部署节点不依赖外部审核API，208条人工标注完成了领取、证据查看和提交链路，昇腾910C完成多卡训练验证。

平台综合优势如下：

证据链可追溯：相较于仅返回分数的调用方式，本平台输出模型理由、红线来源、C2PA 状态、元数据哈希和人工标签，形成可审计证据链。这在法律取证、合规审计场景中具有不可替代性。

国产算力就绪：已完成昇腾 910C 从单卡微调到 16 卡分布式训练的完整验证，并保留训练、推理和通信测试记录；是否具备更广泛的供应链自主能力，还需结合更多模型、算子和版本进行持续验收。

人工复核闭环：完成 208 条去重人工标注（领取→查看证据→提交标签全链路），形成“模型检测 + 人工复核 + 反馈优化”的运营闭环，而非一次性检测工具。

多专家融合架构：将 Deepfake、MLLM、UnsafeBench、PerspectiveVision、NudeNet、Qwen3Guard、SingGuard、规则引擎和 RAG 融合为统一决策系统，避免单一模型的盲区。

在需要数据不出域、证据可审计、国产算力适配、人工复核闭环的政企、金融及媒体审核场景中，本平台提供了一套可私有化部署、可扩展的组合式审核实现；实际部署仍需结合业务数据、合规要求和服务等级进行验收。

数据来源说明：

学术 SOTA 数据：ScienceDirect（TimeSformer）、PubMed（CNN-GAN）、arXiv（VendorBench-100、DeepfakeBench-MM）、CVF（CLIP 跨域评测）；

商用 API 数据：VendorBench-100（arXiv 2607.06254）、腾讯云官方文档、阿里云官方文档、Sightengine 官方文档；

昇腾 910C 数据：36氪/DeepSeek 研究报告、本平台实测；

内容审核服务数据：腾讯云开发者社区实测报告、第三方测评报告。

第四章 创新点与应用价值

4.1 算法创新：面向跨域的Deepfake检测的参数高效适配与多源联合训练方法

4.1.1 LN-tuning研究背景与现有微调范式缺陷

现阶段基于预训练模型的 Deepfake 检测主要分为全参数微调、LoRA 微调、Prefix Tuning 三类主流 PEFT 方案，如图4.1所示，三类方案均存在明显落地短板：

全参数微调：需要更新 CLIP 全部 307M 权重，训练显存占用超过 24GB，中小型实验室、企业无高端 A100 显卡无法开展模型训练；同时完整破坏 CLIP 在全网图文数据习得的通用真实图像先验，模型极易在训练集过拟合，迁移至 Celeb-DF、DFDC 等域外伪造数据集后识别精度断崖下跌，泛化能力极差。

LoRA 微调：仅冻结主干、插入低秩矩阵，虽大幅降低参数量，但每层额外增加线性矩阵前向推理开销，批量检测场景推理延迟显著上升；且 LoRA 适配 Transformer 注意力层，对归一化层特征分布无优化，无法解决真假人脸特征重叠问题。

Prefix Tuning：在每一层输入添加可学习前缀向量，参数量远高于本方案，长人脸图像序列下会产生冗余特征，域外区分能力提升幅度有限。

基于上述问题，本研究在研发阶段围绕 LN-tuning 开展参数高效微调与正则化实验，用于分析轻量化适配策略对训练成本和跨域泛化能力的影响。需要说明的是，LN-tuning 属于研发阶段实验方案之一，当前正式 Deepfake 模型采用多数据集 PEFT 与 SLERP 特征增强策略，不将 LN-tuning 单独作为生产模型的唯一配置。

	全参数微调 (Full FT)	LoRA 微调 (低秩适配)	Prefix Tuning (前缀调优)	LN-tuning (研发实验) (LayerNorm微调)
可训练参数量	≈ 307M (100%)	≈ 4.2M (1.37%)	≈ 31.5M (10.2%)	≈ 0.6M (0.20%) 极少
训练显存占用	> 24 GB (极高)	≈ 9 ~ 12 GB	≈ 13 ~ 16 GB	≈ 6 ~ 8 GB (最低)
推理时延开销	基准时延 (最快)	显著增加 (旁路计算)	中等增加 (前缀冗余)	零额外开销 (与基准一致)
先验与特征	破坏通用先验 / 易过拟合	仅改注意力 / LN未优化	长序列引入冗余特征	保留视觉先验 / 优化分布
跨域泛化性能	严重退化 (断崖式下跌)	提升有限	提升有限	显著提升 (泛化最强)
方案综合评估	成本极高 / 泛化最差	参数少但推理变慢	参数偏多 / 存在冗余	最轻量高效 / 泛化最优

注：参数量与显存占用以 CLIP ViT-L/14 为基准估算；LN-tuning 保持零推理开销且泛化效果最优。

图4.1 研发阶段 LN-tuning 与不同微调方案对比

4.1.2 创新技术链路与工程优化

1. 骨干冻结策略与LayerNorm 优化

本节所述参数量及相关性能数据均来源于研发阶段 LN-tuning 实验，不代表当前生产多数据集 PEFT 模型的完整配置。该实验固定 CLIP ViT-L/14 图像编码器主体参数，仅开放 Transformer 内部 LayerNorm 的缩放因子和偏移因子参与训练，可训练参数量约为 102,400 个，用于分析轻量化微调策略的可行性。

LayerNorm 作为每层特征归一化核心组件，负责将注意力输出特征映射至稳定分布，仅微调归一化参数，能够在完整保留 CL 原生通用图像表征的基础上，自适应学习真实人脸与 AI 伪造人脸的分布差异，在尽量保留预训练视觉先验的同时，使模型适应 Deepfake 数据分布，并在一定程度上缓解跨域过拟合问题，具体的骨干冻结策略与 LayerNorm 优化机制如图 4.2 所示。




图4.2 研发阶段骨干冻结与 LayerNorm 参数高效微调机制

2.多源异构 Deepfake 数据联合训练与跨域适配策略

Deepfake 数据来源于不同生成模型、不同压缩流程以及不同采集环境，其伪造痕迹存在明显域间差异。单一数据集训练容易使模型学习特定生成方法或数据分布特征，导致面对未知生成算法时检测性能下降。针对上述问题，本研究采用多来源 Deepfake 数据联合训练策略，将不同数据集中的真实样本与伪造样本进行统一采样和混合训练，使模型在参数高效调整过程中同时接触多种伪造模式。

具体而言，训练数据覆盖不同类型的人脸伪造模式，包括身份替换、表情驱动、生成式伪造等多种来源；同时引入不同分辨率、压缩比例、编码方式和图像质量变化，以模拟真实互联网传播过程中的内容退化情况。此外，通过融合不同采集设备、光照条件和姿态变化的数据分布，降低模型对于固定场景特征的依赖。

多源联合训练与参数高效微调策略相结合，在冻结CLIP视觉编码器主体参数的基础上，仅通过少量可训练参数学习不同数据域之间的共享判别信息，使模型在保持预训练视觉表征能力的同时，提高面对未知Deepfake生成方法和跨数据集测试环境时的泛化能力。

3. 单位超球面正则化联合损失函数

针对 LN-tuning 仅调整特征归一化分布、但无法显式扩大真实人脸与 AI 伪造人脸在特征空间距离的问题，本研究进一步提出一种单位超球面特征分离正则化策略。

由于 CLIP ViT-L/14 预训练模型学习的是通用视觉语义空间，经过轻量化 LN-tuning 后，模型能够适应 Deepfake 数据分布，但不同来源的真实与伪造人脸仍可能存在高维特征重叠区域，导致跨域检测性能下降。因此，本研究在冻结视觉编码器参数的基础上，引入超球面约束项，对特征方向分布进行显式优化。联合优化目标定义为：

$$L = L_{CE} + \lambda L_{sphere}$$

其中为 L_{CE} 真假二分类交叉熵损失，用于优化基础分类能力； L_{sphere} 为单位超球面正则项，用于约束归一化后的人脸特征向量在单位球面空间中的聚类结构。

具体而言，该约束不改变 CLIP 原始语义空间的整体结构，而是通过优化特征方向，使真实人脸样本向真实类别中心方向聚集，使 AI 生成样本向另一类别方向分布，从角度空间扩大两类样本间隔，提高模型面对不同生成方法时的泛化能力。

与传统 L2 正则仅限制参数幅值不同，本方法针对多模态预训练模型的高维特征空间进行结构化优化，不压缩特征表达能力，而增强真假样本的空间可分性。

研发阶段消融实验中，仅采用交叉熵损失时 Celeb-DF 数据集 AUC 为 0.871，加入单位超球面正则后提升至 0.916。该结果用于分析正则化策略的跨域影响，不作为当前生产模型的正式发布指标。

4. 配套工程优化创新（算法 + 落地联动创新）

单纯的微调算法仅能解决训练阶段的泛化性，要实现从算法到工程的有效落地，必须构建一套高性能的推理架构。为验证研发阶段 LN-tuning 方案的工程可行性，本研究进一步开展缓存索引与半精度推理等工程优化实验，如图 4.3 所示。

SHA-256 图像摘要与缓存索引机制：系统对输入图像计算 SHA-256 摘要，用于文件校验、审计关联及重复任务识别。在具备缓存条件的场景下，可依据摘要识别重复输入，减少不必要的重复计算。SHA-256 同时与当前平台文件安全校验和审计链保持统一；

半精度推理实验：研发阶段曾在 RTX 3060 环境下采用 FP16 推理方式验证模型的资源占用与推理效率。相关延迟结果仅作为早期工程实验记录，不代表当前正式生产节点的固定性能指标。当前正式 Deepfake 训练与评估以昇腾 910C 环境下的 BF16 配置为主要实验口径。



图4.3 研发阶段LN-tuning 工程优化实验机制

4.1.3 研发阶段 LN-tuning 对比实验与量化分析

如图 4.4 所示，研发阶段针对 LN-tuning 及相关正则化策略开展了跨数据集对比实验，用于分析轻量化微调方案在参数规模、训练成本和跨域泛化方面的变化趋势。图中 AUROC、参数量及相关提升幅度均属于研发阶段实验结果，不代表当前生产多数据集 PEFT 模型的正式发布指标。当前平台正式性能统一以独立测试集的 Accuracy、Precision、Recall 和 F1 指标为准。




图4.4 研发阶段 LN-tuning 跨数据集实验结果

4.1.4 完整可复现规范

为保证实验可复现性，当前正式 Deepfake 模型以第三方 CLIP ViT-L/14 checkpoint 为初始化基础，采用多数据集参数高效微调与 SLERP 特征增强策略。正式训练使用 16 张昇腾 910C，采用 BF16 精度，全局 Batch Size 为 64，共训练 20 Epoch，训练样本为 85,696 张，并根据验证集 F1 选择第 6 个 Epoch 作为最佳模型。

最终性能在独立的 DF40 curated held-out 测试集上进行评估，共 3,212 张样本，Accuracy 为 85.59%、Precision 为 83.28%、Recall 为 89.04%、F1 为 86.07%。验证集仅用于模型选轮和调参，不参与最终性能统计。FaceForensics++、Celeb-DF-v2、DFDC、WildDeepfake 及 RTX 3060 等配置仅作为研发阶段实验记录，不代表当前正式训练与测试环境。

4.2 取证创新：双层结构化JSON Prompt与可降级证据输出机制

4.2.1 现有MLLM取证方案缺陷与双层Prompt架构

当前将多模态大模型用于伪造证据提取的相关研究与开源工具存在四类主要工程与证据表达问题：

1. 提示词无标准化约束，采用自由文本指令，模型输出段落长短不定、分析维度混乱，无统一证据字段，难以形成统一、可机器解析的证据记录；
2. 仅适配单一厂商 MLLM，切换 GPT、通义、千问等模型时需要重写全部 Prompt，兼容性极差，复用成本极高；
3. 无异常容错解析逻辑，模型输出夹杂多余注释、换行、自然语言时程序直接崩溃，系统鲁棒性差^[10]；
4. 缺少可视化证据联动机制，仅输出文字描述，无法自动生成伪造热力图，证据直观性不足，不利于审核人员进行复核和证据定位。

针对上述问题，本研究设计了 System 约束层 + User 任务层的双层固定 Prompt 架构，并结合结构化解析、异常降级和可视化证据联动机制，形成面向审核场景的标准化证据输出方案。

4.2.2 创新完整实现技术细节

1. 双层固定 Prompt 架构设计

System 系统角色约束层强制限定模型身份为多模态真实性与视觉风险分析专家，严格规定四大图像分析维度：皮肤纹理重复失真、全局光照不一致、五官边缘拼接痕迹、细节缺失模糊；明确禁止输出无关闲聊、解释性文字，强制仅输出纯 JSON 结构化数据，提前约束输出格式边界，从源头规避杂乱文本。

User 任务执行层（标准化输入模板）统一传入 Base64 编码图像、固定输出字段清单，明确要求包含 **verdict** 真伪判定、置信度、证据列表、可疑人脸区域、完整中文取证说明 5 个必填字段，字段名称、数据类型全部锁定，不允许自定义拓展。两层提示词全部固定文本，无动态随机内容，模型输出结果高度稳定。

2. 跨模型通用兼容接口创新

后端封装统一的模型请求接口，可通过配置切换兼容相应接口规范的多模态模型，从而降低不同模型服务之间的迁移与适配成本。

3. 正则容错解析 + 热力可视化联动创新

容错解析机制：设计多层正则匹配规则，优先提取大括号内完整 JSON；若模型输出夹杂前置 / 后置自然文字、Markdown 标记，自动过滤冗余字符；JSON 解析失败时自动返回 **uncertain** 兜底结果，系统不会中断流程，保障批量检测稳定性。

可疑区域辅助可视化：如图 4.5 所示，当 MLLM 能够输出可用的 **regions** 可疑区域信息时，系统可将相关区域叠加至原始图像，形成辅助可视化结果，并与结构化文字证据关联展示，帮助审核人员快速定位模型关注的局部区域。需要说明的是，该区域信息仅作为解释性视觉线索，不代表精确的像素级伪造定位，也不直接作为最终真实性判定依据。




图 4.5 MLLM 可疑区域辅助可视化示例

4.2.3 结构化 Prompt 机制对比与工程验证

为分析不同 Prompt 约束方式在输出结构、异常处理和工程适配性方面的差异，本文对自由文本 Prompt、单层约束 Prompt 和 System + User 双层结构化 Prompt 的机制特征进行对比，如表 4.1 所示。

表4.1 结构化 Prompt 机制对比

方案	输出结构	异常处理	工程适配性
自由文本 Prompt	输出形式不固定	依赖后处理解析	较难统一归档
单层约束 Prompt	可限制部分输出内容	仍可能出现字 段缺失或格式 噪声	可用于一般结构化任务
System + User 双层 结构化 Prompt	固定 verdict、confidence、evidence、 regions、explanation 等字段	配合结构化解 析与异常降级 机制	便于证据展示、审计归档 和后续决策融合NAWO

双层 Prompt 中，System 层主要负责限定模型角色、分析边界与输出规则，User 层负责约束具体任务和标准字段。两者共同作用，使 MLLM 输出更容易被后端程序解析，并与 Deepfake、内容安全和来源取证等其他证据统一进入决策流程。

为进一步说明结构化输出在异常情况下的工程处理方式，系统针对 JSON 解析失败、服务不可用和证据不足等情况设计了显式降级机制，具体如表 4.2 所示。

表4.2 MLLM 异常场景与降级处置机制

场景	系统处理方式	业务含义
正常返回结构化结果	解析 verdict、证据和解释字段	作为辅助真实性证据
输出包含额外自然语言或 Markdown	提取有效结构化内容并执行容错解析	降低格式波动影响
JSON 解析失败	返回 uncertain 或 inconclusive	不强制判断真实或伪造
模型调用超时或服务不可用	返回 unavailable	保留其他专家结果继续决策
证据不足	返回 uncertain	必要时进入人工复核

当前平台还通过固定来源代理集对通用图片真实性链路进行验证。该测试集共 60 张样本，其中模型形成明确判断 49 张，覆盖率为 81.67%；在已判定样本上 Accuracy 为 91.84%、Precision 为 89.66%、Recall 为 96.30%、F1 为 92.86%。需要强调的是，该结果用于验证当前 MLLM 辅助真实性链路在固定代理分布上的表现，并不等同于双层 Prompt 本身的消融性能，也不能外推为开放世界 AIGC 图片准确率。

4.2.4 工程落地创新价值

结构化 JSON 输出便于前端展示、审计归档、证据检索和多模型融合。模型解析失败或服务不可用时，系统显式返回 uncertain、inconclusive 或 unavailable，并结合其他专家证据或人工复核继续处理，避免单一 MLLM 异常导致整个审核链路中断。

4.3 架构创新：真实性与内容安全双主线与五层协同架构

4.3.1 真实性与内容安全双主线独立建模

平台不把“AI 生成检测”泛化为所有内容风险，而是将真实性鉴别（逐脸 Deepfake、通用图片真实性 MLLM、C2PA 与元数据来源证据）与内容安全审查（红线/隐私/违法）独立建模、独立出证，并在策略层进行融合处置，如图4.6所示。在合

成伪造证件的生产实测中证明，当真实性模型因高超生成技术出现漏检或不确定（uncertain）时，内容安全主线识别出的隐私泄露与违法内容标签仍可提供硬性阻断依据；同理，真实拍摄的照片也不能因未检出伪造而自动放行，必须经过内容安全审查。



图4.6 双主线独立建模

4.3.2 五层架构联动完整创新逻辑

平台在双主线设计基础上，进一步将统一接入、任务编排、双主线证据分析、护栏决策以及人工复核与审计运营等能力抽象为五层协同架构，如图 4.7 所示：

第一层（统一接入与任务编排层）：负责 FastAPI 路由、登录认证、API Key、Scope、限流和配额，对图片、文本及 Agent 请求进行统一鉴权和任务分发。

第二层（真实性证据层）：由人脸检测与逐脸 Deepfake、通用图片真实性 MLLM、C2PA、IPTC/EXIF/XMP/ICC 元数据及 SHA-256 等组件组成，分别输出真实性分数、来源状态及解释证据。

第三层（内容安全与知识证据层）：图片侧由 MultiHeaded+Q16、PerspectiveVision、NudeNet、OCR、MLLM 等专家协同；文本侧结合规则和 RAG v2 红线知识检索，输出风险类别及可追溯知识证据。

第四层（护栏与决策层）：规则、Qwen3Guard、SingGuard、MLLM 及其他专家并行分析，结合输入复检、输出复检、Agent 动作审批与轨迹审查，将多源证据统一映射为 safe/review/unsafe 等业务处置结果。同时，引入 Shadow 模型作为旁路风险评估组件，其不直接参与线上放行或拦截决策，而是在真实业务流量下同步接收输

入样本，模拟新模型、新规则或新策略的判断结果，并与当前线上决策进行差异分析，为模型升级验证、策略灰度发布和潜在风险发现提供依据。

第五层（人工复核与审计运营层）：对模型分歧、证据不足和高风险样本进入人工复核，并通过审计日志、AES-GCM 受控证据、SHA-256 哈希链、驾驶舱和开放 API 形成完整运营闭环。人工复核产生的最终标签作为高可信监督信号，与模型输出及多源证据关联存储，用于审核追踪、模型评估和后续策略优化。




图 4.7 五层协同审核架构

4.3.3 多路混合检索与证据融合机制创新

传统文本审核方法往往依赖单一关键词匹配或单一语义检索，难以同时兼顾显性红线内容的精确识别与隐性语义风险的召回。针对这一问题，本系统构建关键词、字符特征与语义向量相结合的混合检索机制，对法规、标准、平台规则及内部红线知识进行多路证据召回。

其中，关键词链路主要用于识别明确的敏感词、规则名称和高风险表达；字符与词法链路用于增强对拆分、变形及局部相似表达的匹配能力；语义向量链路则基于多语言语义表示检索与输入内容相关的规则和知识片段，提高对同义改写和复杂语义表达的召回能力。不同检索结果经过融合排序、分类过滤与候选筛选后，返回对应的来源文件、知识分类、分块信息及引用片段，为后续审核提供可追溯的政策证据。

需要强调的是，RAG 检索结果仅表示输入内容与知识库条目之间的相关性，不直接等同于最终风险等级。明确命中的确定性红线规则可形成强规则证据，而语义检索结果主要作为辅助证据，与规则、Qwen3Guard、SingGuard、MLLM 等专家结果共同进入统一决策层。

表4.3 不同检索策略的机制与职责对比

检索策略	主要优势	主要局限	系统定位
关键词匹配	对明确红线词和专有表达匹配 直接、可解释	对同义改写和隐性语义覆盖有限	确定性规则证据
字符/词法检索	能补充拆分、变形及局部相似表达	对复杂上下文语义理解能力有限	精确召回补充
语义向量检索	对同义表达、复杂语义具有较强召回能力	相似不等于违规，可能产生语义误召回	辅助知识证据
多路混合检索	综合不同检索方式，提高知识证据覆盖能力	仍需结合规则、专家模型和人工复核	当前 RAG 主检索机制

如表 4.3 所示，多路混合检索并不是简单将某一路结果直接映射为高、中、低风险，而是利用不同检索方式的互补性形成更完整的知识证据，再由后续多专家决策层完成最终风险判断。该设计增强了红线知识检索的可解释性、可追溯性以及复杂表达的适应能力。

4.4 工程创新：面向多专家协同的全链路安全运营平台

4.4.1 工程闭环与协同创新

本作品补齐了实验室算法以外的工程闭环，实现了从模型演示向成熟安全运营平台的跨越，如图4.8所示：

统一异步服务与模型解耦：后端基于 FastAPI 构建统一业务接口，并将图片审核、Deepfake、MLLM、RAG、护栏、Agent 和来源取证等能力按服务与策略层解耦。高算力模型通过独立专家节点接入，使业务编排与模型推理解耦，便于模型升级、故障隔离和资源扩展。

阶段状态与结果反馈机制：系统根据不同任务采用受控轮询或流式更新方式向前端返回任务进度、专家状态和阶段性证据，使审核人员能够及时查看检测过程与中间

结果。对于专家超时、解析失败或服务不可用等情况，前端显式展示 `inconclusive` 或相关异常状态，避免将服务失败误解释为安全。

模块化可插拔设计：平台将图片真实性、内容安全、红线知识检索、文本与 Agent 护栏、来源取证、人工复核及审计运营等能力进行模块化组织，可根据审核场景选择相应检测链路。不同专家通过统一业务编排接入，在保持证据独立性的同时由决策层统一融合处置。**Shadow 模型灰度验证机制：**对于新训练模型、新安全策略或新规则版本，平台支持以 Shadow 模式接入线上审核链路，在不影响业务结果的情况下收集模型输出、风险分布及与主链路决策的差异情况，经离线评估后再决定是否进入正式服务，降低模型升级带来的业务风险。

C2PA来源验证与人工复核闭环：平台采用 `confirmed_source`、`not_found`、`inconclusive` 和 `invalid_or_tampered` 四态表达来源验证结果；模型分歧、证据不足和高风险样本可进入人工复核流程，并通过任务领取、证据查看、标签提交和审计留痕保证复核过程可追溯。人工复核结果形成最终审核标签，与模型预测结果、风险规则命中记录、C2PA来源信息、元数据分析结果以及文件哈希共同组成完整证据链，并进入审计数据库保存。经过脱敏和质量审核后的人工标签可用于后续模型评估、误差分析和策略优化，形成“模型检测—人工确认—策略改进”的闭环机制。

Agent动作绑定授权机制：

针对 Agent 工具调用过程中可能出现的权限扩大和授权复用风险，平台设计动作绑定的一次性授权机制。当 Agent 请求执行高风险动作时，决策层首先对目标工具、参数范围、访问资源和执行上下文进行风险评估，通过审批后生成一次性授权凭证。该凭证仅对应当前动作，不支持跨任务、跨资源或重复调用；执行完成后立即失效，并将授权申请、审批结果、工具调用参数和执行结果写入审计日志，实现 Agent 行为全过程可追溯。

多模态文本证据提取：系统对图片中的文字内容进行 OCR 提取，并与红线规则和 RAG 知识检索联动，使图片视觉风险、文字风险和来源证据能够在统一审核任务中分别展示和综合处置。




图4.8 工程闭环创新亮点

4.4.2 异构部署与工程验收

平台采用正式主站、RTX 4090 专家节点与昇腾 910C 实验/训练节点协同部署。正式主站负责 HTTPS 接入、业务编排、数据库、审计和开放 API；RTX 4090 节点承担 Qwen3Guard、SingGuard、PerspectiveVision 等高算力专家服务；昇腾 910C 节点用于 Deepfake 多卡训练、真实推理和国产化适配验证。各节点通过标准接口解耦，单一模型服务异常不会直接导致整体业务链路失效，便于资源扩展、模型升级与故障隔离。

4.5 场景应用价值与业务适配

结合前述真实性鉴别、内容安全审核、来源验证、多专家护栏及工程化平台能力，本系统并非局限于单一 Deepfake 人脸检测任务，而是面向 AIGC 内容生产、传播和调用过程中的真实性风险、内容安全风险、来源可信性及模型行为安全问题，形成覆盖风险发现、证据分析、人工复核和审计留痕的完整业务闭环。系统可根据不同场景灵活组合 Deepfake、通用图片真实性 MLLM、C2PA、图片内容安全、RAG 红线知识检索、Guard 专家、Agent 安全审查及开放 API 等能力。

在实际应用中，平台可进一步覆盖以下六类典型场景：

(1) 短视频与内容平台。面向用户头像、视频封面、宣传图片、数字人素材及图文动态等内容，在上传和发布阶段调用图片真实性、内容安全和文本护栏能力，对伪造素材、违规内容及高风险文本进行联合审核，并将争议样本提交人工复核。

(2) 新闻媒体与舆情审核。面向新闻配图、热点事件图片、投稿素材及网络传播内容，通过 Deepfake 检测、通用图片真实性分析、C2PA 来源验证和红线知识检索，对内容真实性、来源状态及潜在违规风险分别出证，辅助编辑人员开展发布前审核和争议内容复核。

(3) 政企大模型安全网关。面向政府、企业内部大模型及知识助手，在模型调用前后部署规则、RAG、Qwen3Guard、SingGuard 和 MLLM 等安全专家，对用户 Prompt、模型输出及敏感数据风险进行检查，并结合 API Key、Scope、限流、配额和审计日志实现统一安全治理。

(4) Agent 智能体安全。面向具有工具调用能力的大模型 Agent，对工具名称、调用参数、目标资源、执行结果及完整调用轨迹进行审查。针对高风险写入、删除、外发或权限变更等操作，系统不仅在执行前触发审批，并在执行后对工具结果和轨迹进行再次复检，同时引入动作绑定的一次性授权机制。授权令牌与具体 Agent 动作、目标资源、调用参数以及执行时间窗口绑定，仅允许完成一次指定操作，执行完成或超出有效窗口后自动失效，避免历史授权被重复利用，降低工具滥用、间接提示词注入及越权操作风险。

(5) 版权与来源取证。面向数字作品、媒体素材及争议图片，通过 C2PA、IPTC/EXIF/XMP/ICC 元数据、SHA-256、平台水印及审计记录形成多层来源证据。平台不以单一来源信号直接证明内容真实或 AI 生成，而是将来源声明、文件完整性及审核记录联合展示，为后续版权核验、内容争议处理和审计追溯提供辅助证据。

(6) 教育内容治理。面向高校及教育机构的课程材料、活动图片、申报材料、校园平台内容及大模型教学应用，通过图片真实性检测、内容安全审核、红线知识库、模型输入输出护栏和人工复核等能力，辅助完成材料核验、违规内容识别、大模型使用安全治理及审核流程留痕。

综上，平台已由单点真实性检测工具扩展为覆盖内容平台、媒体审核、政企大模型、Agent 执行安全、来源取证和教育治理等多类业务场景的综合安全平台。不

同场景共用统一的证据、决策、人工复核和审计机制，同时根据业务需求选择不同专家链路，其应用价值如表 4.4 所示。

表 4.4 六类典型业务场景与系统能力映射

场景	适用能力	业务价值
短视频与内容平台	Deepfake、图片内容安全、文本护栏、人工复核	对头像、封面、数字人及图文内容进行发布前风险审核
新闻媒体与舆情审核	Deepfake、MLLM、C2PA、RAG 红线检索	辅助判断素材真实性、来源状态及内容风险
政企大模型安全网关	规则、RAG、Qwen3Guard、SingGuard、MLLM、API 治理	对模型输入输出实施统一安全防护和审计
Agent 智能体安全	动作前审批、工具结果复检、轨迹审查、权限控制	降低越权调用、工具滥用和间接提示词注入风险
版权与来源取证	C2PA、元数据、SHA-256、水印、审计证据	提供来源声明、完整性和内容流转的辅助取证依据
教育内容治理	图片真实性、内容安全、红线知识库、模型护栏、人工复核	辅助材料核验、校园内容治理和大模型使用安全管理

第五章 总结

5.1 作品完成情况

本作品设计并实现了一套集“AI 伪造检测、可解释性分析、内容安全审核及知识库管理”于一体的AIGC 内容安全审计系统，如图5.1所示，系统分别完成了Deepfake、通用图片真实性、图片内容安全、文本护栏、来源取证和人工复核等任务的测试；各项指标仅在对应数据集和评测协议内解释，不合并为单一系统准确率。

（1）多数据集训练的 Deepfake 检测能力

本系统以 CLIP ViT-L/14 checkpoint 为初始化基础，采用多数据集参数高效微调与特征增强策略完成 Deepfake 模型训练。正式训练使用 85,696 张样本，在 16 张昇腾 910C 上采用 BF16 训练 20 Epoch，并根据验证集 F1 选择第 6 个 Epoch 作为最佳模型。最终在独立 DF40 curated held-out 测试集 3,212 张样本上取得 Accuracy 85.59%、Precision 83.28%、Recall 89.04%、F1 86.07%，形成了从人脸检测、质量判断、五点对齐到逐脸推理的完整真实性检测链路。

（2）结构化、可降级的 MLLM 辅助真实性分析

系统采用固定审核提示和结构化解析机制，将 MLLM 输出统一映射为 real、fake 或 uncertain，并保留模型状态、理由和解释证据。解析失败、超时或证据不足时返回 uncertain，不会自动降级为真实。在 60 张固定来源代理样本中，模型形成明确判断 49 张，覆盖率为 81.67%；在已判定样本上 Accuracy 为 91.84%、Precision 为 89.66%、Recall 为 96.30%、F1 为 92.86%。该结果仅反映固定代理分布下的辅助真实性能力。

（3）多专家协同的内容安全与红线知识审核

系统构建规则、RAG 红线知识检索及多模型专家协同的内容安全审核机制。RAG 结合关键词、字符/词法和语义向量等多路信号进行知识召回，并返回来源、分类、分块及引用片段，为审核提供可追溯政策证据；图片侧则结合 PerspectiveVision、NudeNet、OCR、MLLM 等专家进行内容安全分析。RAG 相关度不直接等同于风险等级，而是与其他专家证据统一进入决策层生成 safe、review 或 unsafe 等业务结果。

（4）多专家协同与异构部署的工程化平台

系统采用 FastAPI 后端与 Vue3 前端的分离架构，并将 Deepfake、MLLM、内容安全、RAG、护栏、Agent、来源取证及人工复核等能力进行服务化解耦。正式主站承担业务接入、策略编排、数据库、审计和开放 API，RTX 4090 节点承担高算力专家服务，昇腾 910C 节点用于 Deepfake 训练、推理验证及国产化适配。平台同时支持 C2PA 四态来源验证、异常状态显式降级、人工复核与审计留痕，形成完整的安全运营闭环。



图 5.1 AIGC 内容安全审计系统核心能力与测试成果

5.2 现存不足后续优化

对照本项目的主要设计目标，如图5.2所示，系统现阶段仍存在部分能力局限：

（1）视频与音频检测能力有待完善

当前系统重点支持静态图像、文本与对话的安全检测。对视频 Deepfake（如 Wav2Lip 生成的唇语伪造视频）需逐帧处理，效率低下且无法利用帧间时序信息。在视频伪造检测方面还需要进一步引入时序建模。未来将引入 3D-CNN 或 Video Transformer 架构，实现端到端的视频伪造检测。此外，音频安全方面目前尚需独立的声学与时语义评测，这也是后续优化的关键

（2）跨域鲁棒性与对抗样本防御待加强

当前独立测试与跨生成器实验仍无法覆盖开放环境中的全部生成器、压缩方式和潜在对抗扰动，模型在新分布下仍可能出现性能下降。因此，平台保留多证据链与人工复核机制。后续可通过更丰富的跨域数据、对抗训练与数据增强进一步提高模型鲁棒性。

（3）多模态审核的一致性仍需提升

当前平台已经覆盖图片内容安全、OCR 文本审核、RAG 红线检索以及大模型输入输出护栏，但不同模态仍采用相对独立的专家和评测体系，尚未形成统一的视频、音频及跨模态联合风险表示。后续将进一步完善跨模态证据融合与统一评测机制，提高复杂图文、音视频场景下的协同审核能力。

（4）人工复核数据规模与评估机制仍需完善

当前正式站已完成 208 条去重人工复核记录的完整链路验证，所有样本均满足任务领取、受控证据访问和人工标签提交要求，证明人工复核流程已经形成闭环。但现有人工标注规模仍相对有限，主要来源于正式运营流量，尚不足以替代预先冻结的独立公开测试集。后续需持续扩大真实业务人工标注规模，用于阈值校准、分歧分析和模型迭代。

（5）外部水印技术的适配与隐私限制

当前平台已支持 C2PA、元数据及平台自有水印等来源证据，但 SynthID、Stable Signature 等闭源或需授权的官方检测能力尚未正式接入。对于第三方来源验证服务，仅在用户明确授权后调用；服务未配置、超时或不可用时需显式保留相应异常状态，不得将调用失败解释为“未检测到水印”。后续将在满足授权、隐私与接口合规要求的前提下进一步扩展外部来源验证能力。




图5.2 现存不足及优化方向

5.3 安全、隐私与伦理约束及未来展望

随着AIGC技术的持续演进，内容安全检测面临的挑战也在不断升级。未来工作将从以下方向展开：

人工审核闭环与数据指标细化：当前正式站已完成 208 条去重人工复核记录的完整链路验证，覆盖任务领取、受控证据查看与人工标签提交。后续将继续扩大真实业务人工标注规模，并引入更丰富的授权样本，分层报告召回率、误报率、P95 延迟及失败降级等指标，用于阈值校准和模型迭代。

主动防御与专用护栏模型：结合人脸伪造主动防御体系的研究进展^[25]，后续将继续研究平台自有隐形水印、第三方来源凭证适配及专用安全模型，在明确授权、算力成本和安全边界后逐步扩展主动防御能力，并坚持不将通用模型冒充专用安全模型。

多模态与多语言能力拓展：进一步深入研究视频时序检测、音频风险审核以及对抗训练。同时扩展内容安全审核模块对英语、粤语等多语言的支持，以适应国际化应用场景。在演进过程中，将持续维持严格的隐私评审与素材许可证审查。

隐私保护训练机制：后续可探索联邦学习或其他隐私保护训练方式，在不直接汇聚敏感原始数据的前提下提升跨机构模型训练能力。

实时流媒体检测：针对直播和视频流场景，后续将研究低延迟的实时 Deepfake 检测与时序建模方案，在保证检测稳定性的前提下持续优化端到端响应时延。

参考文献

- [1] Cao Y, Li S, Liu Y, et al. A survey of AI-generated content (AIGC): A history of generative AI from GAN to ChatGPT[J]. ACM Computing Surveys, 2025, 57(9): 1–38.
- [2] Rombach R, Blattmann A, Lorenz D, et al. High-resolution image synthesis with latent diffusion models[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2022: 10684–10695.
- [3] Chandra N, Murtfeldt R, et al. Deepfake-Eval-2024: A multi-modal in-the-wild benchmark of deepfakes circulated in 2024[J]. arXiv preprint arXiv:2503.02857, 2025.
- [4] 刘晓龙, 刘欢, 赵耀, 等. AIGC伪造内容被动检测与主动防御技术综述[J]. 中国科学: 信息科学, 2025, 55(9): 2250–2288.
- [5] Wang S Y, Wang O, Zhang R, et al. CNN-generated images are surprisingly easy to spot... for now[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2020: 8695–8704.
- [6] Rossler A, Cozzolino D, et al. FaceForensics++: Learning to detect manipulated facial images[C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV). New York: IEEE, 2019: 1–11.
- [7] Li Y, Yang X, et al. Celeb-DF: A large-scale challenging dataset for deepfake forensics[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2020: 3207–3216.
- [8] Dolhansky B, et al. The deepfake detection challenge (DFDC) dataset[J]. arXiv preprint arXiv:2006.07397, 2020.
- [9] Zi B, Chang M, et al. WildDeepfake: A challenging real-world dataset for deepfake detection[C]//Proceedings of the 29th ACM International Conference on Multimedia. New York: ACM, 2021: 2382–2390.
- [10] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[C]//International Conference on Learning Representations (ICLR), 2021.

- [11] Ji Y, Yan H, Lan J, et al. Interpretable and reliable detection of AI-generated images via grounded reasoning[J]. arXiv preprint arXiv:2506.07045, 2025.
- [12] Konsheng. Sensitive-lexicon: 中文开源敏感词词库[EB/OL]. GitHub, 2026. <https://github.com/konsheng/sensitive-lexicon>
- [13] Reimers N, Gurevych I. Sentence-BERT: Sentence embeddings using siamese BERT-networks[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2019: 3982–3992.
- [14] Chroma. Chroma: Embeddings database for LLM applications[EB/OL]. <https://trychroma.com>, 2022.
- [15] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//International Conference on Machine Learning (ICML). PMLR, 2021: 8748–8763.
- [16] Yermakov A, Cech J, Matas J. Unlocking the hidden potential of CLIP in generalizable deepfake detection via LN-tuning[J]. arXiv preprint arXiv:2503.19683, 2025.
- [17] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]//Advances in Neural Information Processing Systems (NeurIPS), 2020: 9459–9474.
- [18] Gao Y, Xiong Y, Gao X, et al. Retrieval-augmented generation: A survey[J]. arXiv preprint arXiv:2312.10997, 2023.
- [19] PaddlePaddle. PaddleOCR: Multi-lingual optical character recognition toolkit[EB/OL]. GitHub, 2020. <https://github.com/PaddlePaddle/PaddleOCR>
- [20] Tiangolo S. FastAPI: Modern, fast (high-performance) web framework for building APIs with Python 3.8+[EB/OL]. <https://fastapi.tiangolo.com>, 2018.
- [21] Vue Team. Vue 3.0 progressive JavaScript framework[EB/OL]. <https://vuejs.org>, 2020.
- [22] Element Plus Team. Element Plus: Vue 3 UI component library[EB/OL]. <https://element-plus.org>, 2021.

- [23] Chen T, Guestrin C. XGBoost: A scalable tree boosting system[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2016: 785–794.
- [24] Zhang K, Zhang Z, Li Z, et al. Joint face detection and alignment using multitask cascaded convolutional networks[J]. IEEE Signal Processing Letters, 2016, 23(10): 1499-1503.
- [25] 瞿左珉, 殷琪林, 盛紫琦, 等. 人脸深度伪造主动防御技术综述[J]. 中国图象图形学报, 2024, 29(2): 318–342.