



中国信息安
全测评中心

2 26



第十九届全国大学生信息安全竞赛暨 第三届“长城杯”网数智安全大赛 作品赛（自由作品赛）

面向 AIGC 伪造的跨域泛化检测 与可解释性防御平台



团队名称：A244-全部都队



跨域检测



跨域泛化



可信取证



RAG审核



内容安全

目录

CONTENTS



01

背景与挑战

02

系统架构总览

03

核心创新点

04

对比分析与应用价值

05

总结展望



随着AIGC进入规模化应用，安全治理正从“单一真假鉴别”走向“真实性、内容安全、来源可信与模型行为”的全链路协同防御。

! AIGC风险面持续扩张

- Deepfake、违规图文、提示词注入、模型输出风险不断叠加
- 风险已由内容层延伸至模型层与执行层



深度伪造



违规图文




提示词注入



Agent/工具
执行风险

! 检测结果可信性不足

- 单数据集模型跨域泛化弱，面对新型伪造方式易失效
- 传统系统往往只给真假分数，缺少可解释证据链
- 来源凭证与模型结论难以交叉验证



! 安全防御与审计体系割裂

- 图片、文本、来源、模型与Agent安全能力各自为战
- 缺乏统一决策、人工复核、证据留存与故障兜底



本项目定位:以跨域AIGC伪造检测为核心，融合内容安全、来源取证、模型/Agent护栏与审计运营的

可私有化AIGC安全防御平台



真实性鉴别



内容安全



来源可信



行为安全



审计追溯

背景与挑战

系统架构总览

核心创新点

对应分析与应用价值

总结展望


现有方案的四项关键挑战

单点检测技术难以同时满足跨域稳健、可信取证、协同防御与工程审计需求。需要构建兼顾检测、证据、协同与审计的一体化AIGC安全防御平台




跨域泛化不足

域内表现较好，但面对新生成器、新数据分布时性能明显下降



证据链缺失

只输出真假标签与置信度，缺少异常区域、判定依据与来源证据
结果难复核、难追溯、难进入审计流程



工具功能割裂

真实性、内容安全、来源验证、模型/Agent安全能力彼此割裂
多类风险难以统一编排与协同判定



工程落地断层

算法原型难进入真实审核业务
缺乏任务编排、人工复核、证据留存、权限治理与故障兜底



系统总体架构

真实性鉴别与内容安全双主线独立建模，破除“AI生成=不安全”的简单逻辑



多证据判定机制

不同证据回答不同问题，
破除“AI 生成 = 不安全”的简单逻辑

	← 合规 →	← 违规 →
	真实且合规	真实但违规
真实实拍 (Y轴上方)	 正常放行	 案例：真人实拍涉黄/暴力 处置：【内容安全阻断】
	AI生成但合规	AI生成且违规/诈骗
AI生成 (Y轴下方)	 案例：AI绘画、虚拟主播 处置：【真实性标明，不阻断】	 案例：换脸诈骗、AI生成涉暴 处置：【双重违规，全面拦截】

背景与挑战

系统架构总览

核心创新点

对应分析与应用价值

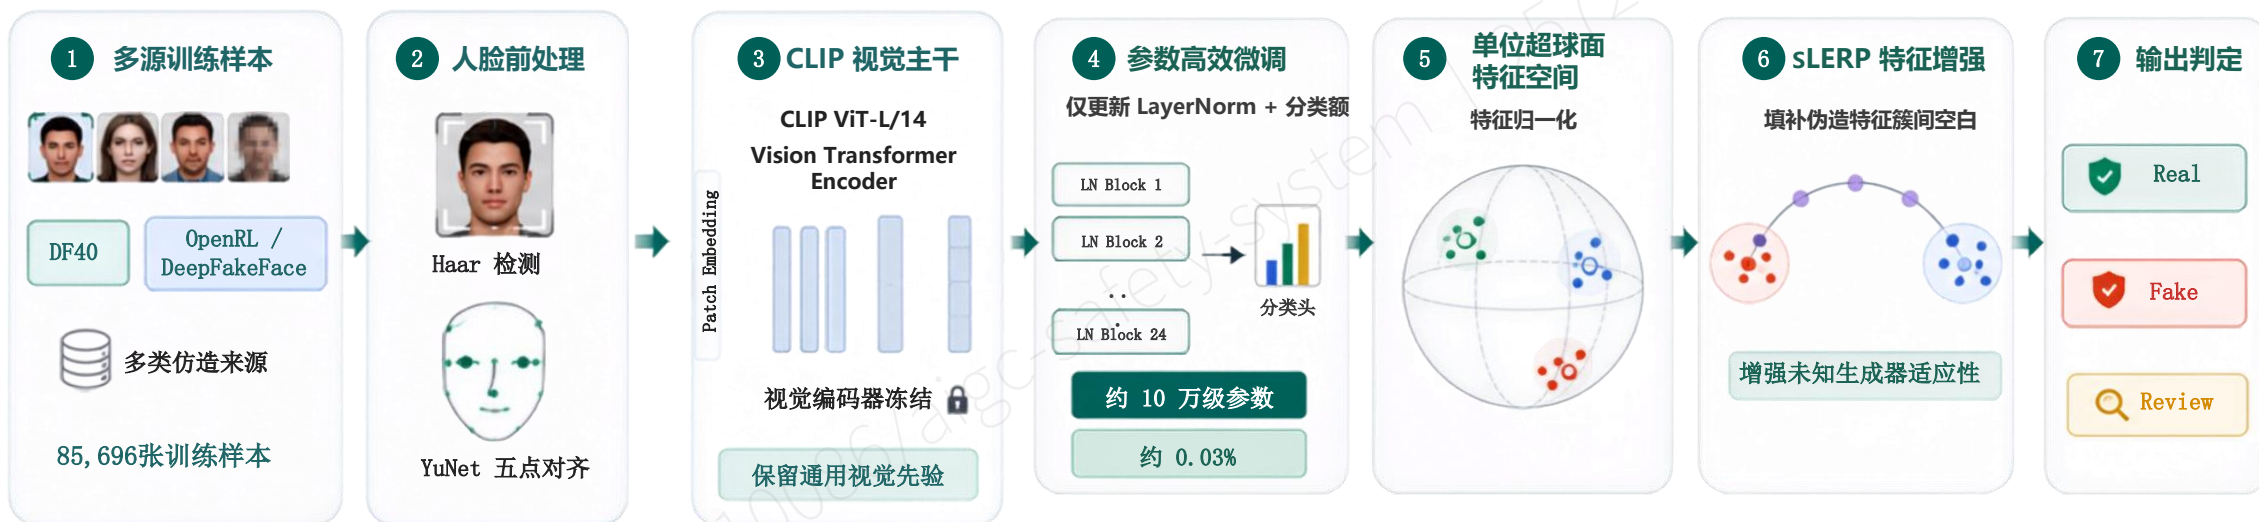
总结展望

参数高效适配与SLERP特征增强的跨域Deepfake检测

冻结CLIP通用视觉主干，结合多源训练、LN-tuning与球面特征增强，提升未知伪造分布下的检测稳健性。

CLIPViT-L/14跨域Deepfake检测技术链路

视频数据经抽帧形成训练样本，生产环境执行图像级逐脸检测。



16x Ascend 910C
HCCL DDP • BF76



20 Epoch
验证集F1选模 :Epoch 6



3,212 张
独立测试集



F1 86.07%
正式发布口径



核心价值：以极少可训练参数保留CLIP泛化能力，并通过SLERP特征增强提升跨生成器稳健性。

背景与挑战

系统架构总览

核心创新点

对应分析与应用价值

总结展望

昇腾910C多卡训练与算子适配

从PyTorch到torch-npu/HCCl的完整适配与训练闭环，证明系统已在国产算力上完成大规模训练。


```
root@atlas-42 | Ascend live session | 2026-08-17 11:36 CST

$ npu-smi info
npu-smi 25.5.2
Version: 25.5.2
NPU Name Health Power(W) Temp(C) HBM-Usage(MB)
0 Ascend910 OK 161.0 42 63714 / 65536
1 Ascend910 OK 161.1 40 63592 / 65536
2 Ascend910 OK 167.2 43 63598 / 65536
3 Ascend910 OK 161.0 43 63633 / 65536
4 Ascend910 OK 164.3 41 21374 / 65536
5 Ascend910 OK 172.2 40 3114 / 65536
6 Ascend910 OK 170.5 44 3128 / 65536
7 Ascend910 OK 166.8 42 3115 / 65536
physical device entries: 0-15 | all health: OK

NPU processes
0:0 pid 1414203 VLLMWorker_TP 60604 MB
0:1 pid 1415336 VLLMWorker_TP 60504 MB
1-3 VLLMWorker_TP x6 60444-60524 MB
4:0 pid 1601939 python 18296 MB

$ POST http://127.0.0.1:8000/v1/chat/completions
model: qwen3-72b-a22b-instruct-2507-w8a8-modelslim
request_id: chatcmpl-9a01606710cf6056
output: Ascend inference OK
usage: prompt=15 completion=5 total=20 tokens
Evidence source: SSH read-only checks on 100.121.203.95
```

算子适配与训练流程



✓ FP64 统计归约
→ BF16 / FP32 兼容路径

✓ DDP 梯度同步
+ checkpoint 校验

✓ 算子、通信、内存
全链路稳定适配



85,696 张
多源训练样本

DF40 + DeepFakeFace



20 Epoch
训练总轮次



46 分 23 秒
总耗时



Best Epoch = 6
验证集F1最优

16 卡训练监控摘录

设备 0-15 • HCCL 同步 • 全卡参与

BF16 | 每卡batch4, 全局batch64



背景与挑战

系统架构总览

核心创新点

对应分析与应用价值

总结展望

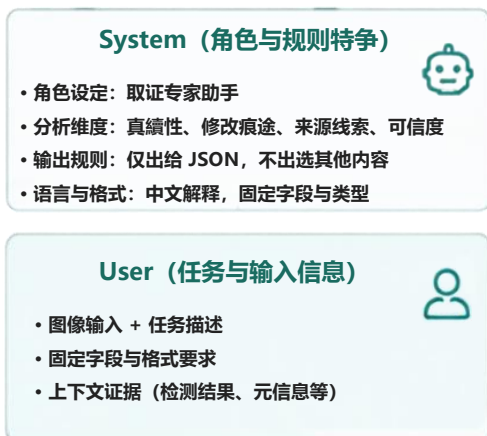
双层Prompt驱动的MLLM结构化证据输出与可解释分析

通过双层固定Prompt 约束输出，生成标准化JSON证据链，结合容错解析与多源证据融合，提升可解释性与跨域泛化能力。

1 输入证据 (Input)



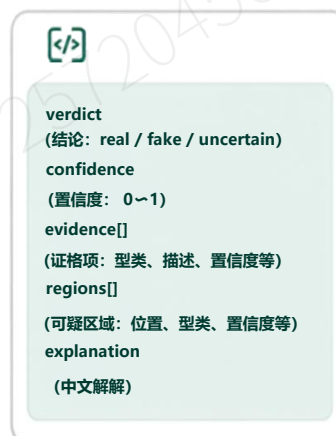
2 双层固定 Prompt 约束



3 MLLM 辅助真实性分析




4 固定 JSON Schema 输出



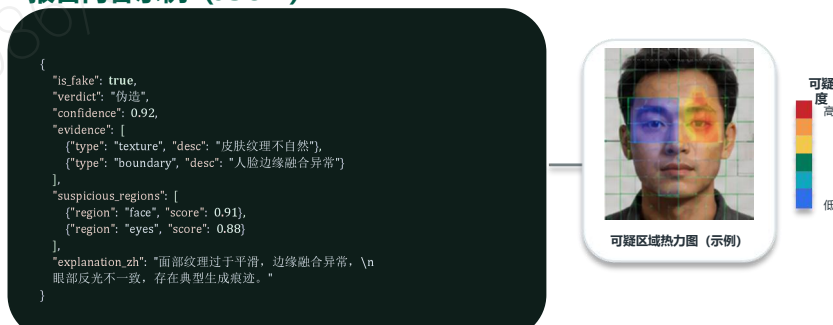
5 容错解析与降级机制



MLLM可解释性原理



报告内容示例 (JSON)



多源证据融合与决策



图片内容安全多专家级联

采用“轻量初筛—高召回二审—专项区域检测—语义与文字联动”的多专家级联机制。



红线知识库与RAGv2混合检索

面向法规、国家标准、平台规则与内部红线的可追溯知识证据层



以语义向量+中文词法混合检索兼顾泛化召回与精确匹配，为大模型安全护栏提供可追溯、可引用、可审计的知识证据

背景与挑战

系统架构总览

核心创新点

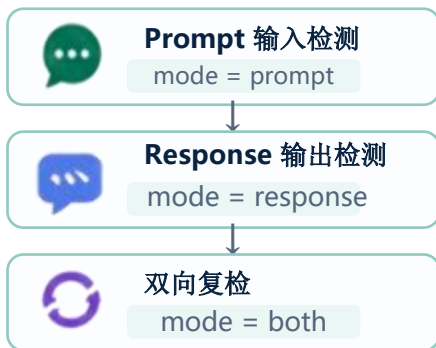
对应分析与应用价值

总结展望

多专家协同的大模型安全护栏

面向 Prompt 与模型输出的双向检测，通过规则、RAG 与安全专家并行分析，实现分级防护与保守风险决策。

1 双向检测入口



Rule Engine

低延迟
始终执行

输入护栏

模型调用

输出护栏

① 输入 Unsafe 可阻断模型调用；
输出 Unsafe 进入隔离/拦截。

2 三级可配置安全护栏

⚙️ 系统支持可配置启用，默认配置未必全部同时在线开启。



3 并行专家分析

并行执行，独立输出风险证据



4 风险融合与处置

同类别取最高有效证据

不做低分平均稀释，避免高风险信号被弱化。



SAFE /
ALLOW



REVIEW



UNSAFE
/BLOCK



专家状态进入审计链路：
executed / skipped /
unavailable / inconclusive



异常状态显式记录，
不伪造为低风险证据。

◆ 核心价值

形成“规则快速拦截—多专家并行分析—最高风险融合—输入前阻断—输出后隔离—全链路审计”的大模型安全护栏闭环

Agent 执行安全

将安全边界从 Prompt / Response 延伸至 Agent 实际执行过程，覆盖执行前、执行后与完整轨迹。



创新价值：将安全边界由 Prompt / Response 内容审核延伸至 Agent 实际执行过程，形成“执行前风险控制 — 高风险动作授权 — 执行后结果复检 — 完整轨迹审计”的闭环防护。

背景与挑战


系统架构总览

核心创新点

对应分析与应用价值

总结展望

来源取证与可信审计证据链



安全接入、异步编排与全流程审计

系统通过安全接入、异步编排和流式证据反馈，将多模型能力组织为可降级、可复核、可追溯的审计闭环。



FastAPI安全接入

- API Key / Scope / 限流与配额
- 文件校验与统一任务编排
- 插件化专家接入与故障隔离




Vue3审计工作台

- 模块化检测链接场景启停
- 证据卡 / 风险状态 / 人工复核
- 工作台、数据总览、驾驶舱联动



异步并发与证据流


- 多专家并行，完成即返回
- SSE推送阶段状态与中间证据
- 超时 / 故障显式标记，不误判为安全



安全审核工作台



阶段证据流



人工复核与审计记录

安全工程价值：统一接入 → 并行检测 → 阶段证据 → 风险决策 → 人工复核 → 审计留痕

背景与挑战

系统架构总览

核心创新点

对应分析与应用价值

总结展望

实验环境与评估设计

为验证系统在真实场景下的可用性与有效性，从正式训练、独立测试、跨生成器外测、多维安全评测与工程验收等五个维度开展系统化评估。



检测主干

CLIP ViT-L/14



参数高效适配

LN-tuning



正式训练

16× Ascend 910C



评测协议

Hold-out / 5-Fold / OOD

评测任务与数据划分

评测任务	数据规模	验证目标	核心指标
Deepfake正式训练	85,696张	多源联合训练与模型收敛	—
独立保留测试	3,212张	最终性能报告	Accuracy / Precision Recall / F1
跨生成器外测	Inpainting 30,000 InsightFace 30,000	OOD泛化能力	Fake Recall
图片内容安全	UnsafeBench 2,037张	违规内容识别	Recall / F1 / P95
Agent安全	NSFA 3,435条	注入与恶意请求防护	Precision / Recall/ F1 / 延迟

① 说明：不同任务独立评测，不合并为“系统总准确率”；正式性能口径以独立测试集与专项测试结果为准。

训练与部署环境



核心训练环境

NPU: 16× Ascend 910C
并行: HCCL DDP
精度: BF16
Epoch: 20




平台验证环境

GPU: NVIDIA RTX 3060 (6GB)
CPU: Intel Core i7-12700H
内存: 16GB DDR5
系统: Windows 11



软件栈: Python 3.11 · PyTorch 2.2.0 · FastAPI 0.110.0 · Vue 3.4.0 · ChromaDB 0.4.22

整体评测流程



背景与挑战

系统架构总览

核心创新点


对应分析与应用价值

总结展望

检测性能结果：独立测试与跨生成器泛化验证

正式模型采用独立保留测试集统一报告性能，并通过未知生成器外部数据验证跨域迁移能力。

跨生成器外部测试（未知生成器）



① 外部数据未参与训练，仅含伪造样本，因此统一报告 Fake Recall。

正式训练配置



☆ 多数据集 PEFT + SLERP 特征增强 | 按验证集 F1 选模

正式模型独立测试

3,212 张
独立测试样本

85.59%

Accuracy

83.28%

Precision

89.04%

Fake Recall

86.07%

F1

统一发布口径：Accuracy / Precision / Fake Recall / F1

验证集仅用于选模；独立测试集不参与调参。

独立测试混淆矩阵



背景与挑战

系统架构总览

核心创新点

对应分析与应用价值

总结展望

核心创新与系统落地

工作贡献同时覆盖算法创新、架构设计、工程落地与安全运营，形成从检测到决策的全链路闭环。

01



算法创新

跨域泛化检测

多数据集 PEFT + SLERP 特征增强，提升跨数据源与未知生成方式下的识别稳定性。

02



取证创新

结构化证据输出

System + User 双层 Prompt + JSON Schema + 容错降级，实现可解析、可展示、可归档证据。

03



架构创新

双主线与五层协同

真实性与内容安全独立建模，融合来源取证与模型 / Agent 安全证据，统一分级决策。

04



工程创新

全链路安全运营闭环


异步编排 + 显式降级 + Shadow 灰度 + 人工复核 + 异构部署，实现可部署、可审计运营。

工程实现与验证



85,696 张

多源训练样本



16× Ascend 910C

国产算力训练



3,212 张


独立保留测试集



86.07%

Deepfake F1

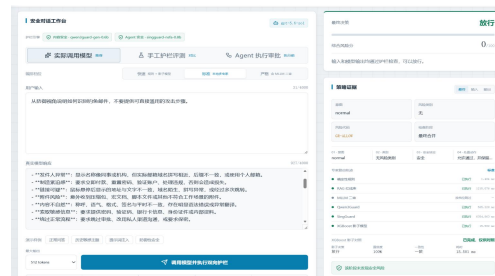
• 从算法能力到可运行平台：检测 → 出证 → 决策



① 真实性鉴别



② 结构化证据



③ 内容安全审计



核心价值

通过算法、架构与工程的协同创新，构建覆盖真实性鉴别、内容安全防护、Agent 执行安全与来源取证的一体化平台，支撑可落地、可审计、可持续演进的 AIGC 安全运营体系。

背景与挑战

系统架构总览

核心创新点

对应分析与应用价值

总结展望

不足与未来展望

AIGC检测的核心应用价值将从身份溯源转向质量审计。



当前不足



视频 / 音频时序能力不足



开放环境鲁棒性仍需提升



人工复核样本与统一评测规模有限



能力边界



多模型输出属于风险证据



不将“AI生成”直接等同于“不安全”



争议样本与证据冲突进入人工复核



未来方向



视频时序与实时流媒体检测



主动水印与来源凭证



多模态 / 多语言统一审核



联邦学习与隐私保护训练



专用护栏模型与更强安全工程



从“判断是否由 AI 生成”，走向

真实性鉴别 + 内容安全 + 来源可信 + 行为安全 + 可审计处置

构建覆盖生成、传播、使用全链路的 AIGC 安全运营体系，服务可信 AI 与负责任的智能社会。

背景与挑战

系统架构总览

核心创新点

对应分析与应用价值

总结展望



中国信息安全
测评中心

2 26



第十九届全国大学生信息安全竞赛
暨第三届“长城杯”网数智安全大赛

感谢聆听

· 敬请各位评委老师指导 ·

面向AIGC伪造的跨域泛化检测与可解释性防御平台



跨域检测



跨域泛化



可信取证



RAG审核



内容安全



团队名称：A244-全部都队

